# Deskriptivna statistika

# Table of contents


0.1 Deskriptivna statistika . . . 2
0.1.1 Mjere centralne tendencije . . . 4
0.1.1.1 Aritmetička sredina . . . 4
0.1.1.2 Medijan . . . 7
0.1.1.3 Mod . . . 10
0.1.1.4 Izbor odgovarajuće mjere . . . 12
0.1.2 Mjere disperzije . . . 14
0.1.2.1 Raspon . . . 14
0.1.2.2 Međukvartilni raspon (IQR) . . . 15
0.1.2.3 Varijanca i standardna devijacija . . . 17
0.1.2.4 Usporedba mjera disperzije . . . 21
0.1.3 Standardizirani rezultati i korelacije . . . 22
0.1.3.1 Z-vrijednosti . . . 22
0.1.3.2 Pearsonov koeficijent korelacije . . . 25
0.1.4 Vizualizacija podataka . . . 29
0.1.4.1 Histogram . . . 29
0.1.4.2 Box plot . . . 31
0.1.4.3 Dijagram raspršenja . . . 33
0.1.4.4 Stupčasti grafikon . . . 34
0.1.4.5 Principi učinkovite vizualizacije . . . 36
0.1.5 Cjeloviti primjer: od sirovih podataka do deskriptivnog izvještaja . . . 37
0.1.6 Sažetak poglavlja . . . 42


## 0.1 Deskriptivna statistika

Zamislimo opsežnu situaciju u istraživačkoj praksi: komunikologinja je upravo završila anketno istraživanje o medijskim navikama studenata komunikologije na trima hrvatskim sveučilištima, tj. institucionalno reprezentativnu studiju koja vašcha petsto ispitanika. Prikupljeni su podaci o dnevnom vremenu provedenom na društvenim mrežama, broju informativnih portala koje redovito prate, razini povjerenja u medije i nekoliko drugih varijabli. Pred njom se nalazi proračunska tablica s tisućama numeričkih vrijednosti raspoređenim u mnoštvo stupaca i stotine redaka – njihova sirova masa, bez interpretativnog okvira, ostaje gotovo nečitljiva. Vizualni pregled samih brojeva ne pruža nikakav smislen uvid u osnovne obrasce ili distribucije jer je količina informacija prevelika za čitanje kroz direktnu inspekciju. Neophodan je sustavni pristup transformaciji tih podataka u čitljive i interpretabilne uvide, što je upravo zadaća deskriptivne statistike, tj. skupa statističkih metoda kojima se

prikupljeni podaci sažimaju, organiziraju i prezentiraju na način koji omogućuje njihovo razumijevanje, komunikaciju i učinkovitu razmjenu znanja.

**Deskriptivna statistika** razlikuje se od inferencijalne statistike budući da ne pokušava ekstrapolirati zaključke o široj populaciji na temelju empirijskog uzorka, već jednostavno i sustavno opisuje podatke koji su stvarno prikupljeni. Iako inferencijalna statistika, koju ćemo obraditi u poglavlju 9, koristi uzorak kao sredstvo za procjenu karakteristika populacije i testiranje teorijski postavljenih hipoteza, deskriptivna statistika fokusira se na konkretna pitanja: koja je reprezentativna vrijednost podataka, u kolikoj mjeri su ti podaci raspršeni oko te sredine, postoje li neuobičajene ili ekstremne vrijednosti i kakav je oblik međusobnog odnosa između dviju ili više varijabli. Odgovori na ova fundamentalna pitanja čine temelj svake buduće statističke analize i predstavljaju nužan preduvjet za bilo kakve naprednije analize, nadalje čineći deskriptivnu statistiku prvim i kritičnim korakom u svakom istraživačkom procesu. Istraživač koji nije solidno upoznat s deskriptivnim tehnikama sličan je graditelju koji počinje gradnju kuće bez snažnog temelja – sve što slijedi neizbježno će biti nestabilno i neispravno.

U kontekstu komunikološkog istraživanja, deskriptivna statistika ima nenadmašnu praktičnu vrijednost budući da se primjenjuje na brojne praktične scenarije. Analiza gledanosti televizijskih programa, posjećenosti internetskih portala, stupnja angažmana na društvenim mrežama ili sistematična klasifikacija tematskih kategorija u medijskom sadržaju – svi ovi empirijski poduhvati zahtijevaju solidno poznavanje i pouzdanu primjenu deskriptivnih tehnika. Istraživač koji ne razumije metodološku razliku između aritmetičke sredine i medijana može donijeti bitno pogrešne zaključke o "tipičnoj" gledanosti televizijske emisije budući da čak i jedna ekstremna vrijednost značajno iskrivljava prosjek. Analitičar koji zanemaruje standardnu devijaciju kao mjeru varijabilnosti može propustiti kritičan uvid da je publika jednoga portala konzistentna u svakodnevnoj posjećenosti, dok je publika drugoga portala izrazito varijabilna, tj. nepredvidiva. Netko tko ne vizualizira podatke prije izračunavanja korelacijskih koeficijenata rizikuje da propusti nelinearni ili krivolinijski odnos koji Pearsonov koeficijent jednostavno ne registrira. Stoga je ovladavanje tehnikama deskriptivne statistike nužan i ključan preduvjet za bilo koje kompetentno istraživanje u polju masovne komunikacije.

Ovo poglavlje organizirano je u četiri osnovne cjeline koje čine logičnu progresiju od najjednostavnijih do složenijih koncepata. U prvoj se obrađuju **mjere centralne tendencije** – aritmetička sredina, medijan i mod – koje omogućuju pronalaženje reprezentativne ili "središnje" vrijednosti u skupu podataka, nadalje odgovarajući na pitanje kakva je "tipična" opservacija u analiziranom skupu. Druga cjelina je posvećena **mjerama disperzije ili varijabilnosti** – rasponu, međukvartilnom rasponu, varijanci i standardnoj devijaciji – koje kvantificiraju intenzitet raspršenosti podataka oko izdvojene srednje vrijednosti, tj. govore nam koliko se tipično pojedinačne opservacije udaljuju od tog središta. Treća cjelina sistematizira koncept **standardiziranih rezultata i korelacijskih analiza**, tj. metoda za normalizaciju varijabli mjerenih na različitim skalama i za empirijsku kvantifikaciju sistematskog odnosa između dviju ili više varijabli. Konačno, četvrta cjelina obrađuje **vizualizaciju podataka** kao nenadoknadivu komponentu deskriptivne analize, obuhvaćajući histogram, box plot, dijagram raspršenja i stupčasti grafikon kao temeljne grafičke prikaze. Svaki od ovih pristupa demonstriran je na primjerima imanentnim hrvatskom medijskom kontekstu,

uz praktične ilustracije statističkog programa R kojima se odgovarajući izračuni provode u stvarnoj istraživačkoj praksi.

### 0.1.1 Mjere centralne tendencije

**Mjere centralne tendencije** mogu se definirati kao statističke vrijednosti koje iz raznolike mase numeričkih podataka ekstrapoliraju jednu reprezentativnu vrijednost, koja sumativno i najjednostavnije opisuje "središte" ili "centar" distribucije. Zamislimo konkretnu situaciju: urednica večernjih vijesti HRT-a pregledava podatke o gledanosti svoje emisije tijekom mjeseca dana. Gledanost varira od dana do dana s vrijednostima poput 320.000 gledatelja u ponedjeljak, 280.000 u utorak, zatim 210.000 vikendom, što čini listu od trideset različitih brojeva bez jasne strukture. Pred njom stoji praktično pitanje kako sažeti toliku masu podataka u jedan ili nekoliko razumljivih brojeva. Želi odgovoriti na intuitivno jednostavno pitanje koje se često postavlja u praksi: kolika je "tipična" ili "uobičajena" gledanost ovoga programa. Međutim, odgovor na to naizgled jednostavno pitanje nije jednoznačan jer se pojam "tipično" može operacionalizirati na više različitih načina, svaki s različitim matematičkim i interpretativnim svojstvima. Statistika nudi tri glavne mjere centralne tendencije, naime aritmetičku sredinu, medijan i mod, od kojih svaka odgovara na pitanje "koja je tipična vrijednost" na različit način, a svaka nosi sa sobom vlastite prednosti i značajna ograničenja ovisno o vrsti podataka i o specifičnom istraživačkom kontekstu.

#### 0.1.1.1 Aritmetička sredina

**Aritmetička sredina**, u svakodnevnom jeziku poznata i kao "prosjek", predstavlja najčešće primjenjivanu mjeru centralne tendencije u kvantitativnom istraživanju. Izračunava se zbrajanjem svih vrijednosti u skupu podataka i dijeljenjem dobivene sume s brojem ukupnih opservacija. Matematički se označava simbolom $\bar{X}$ (koji se čita kao "iks bar") i formalno se definira sljedećom jednadžbom:

$$\bar{X} = \frac{1}{N}\sum_{i=1}^{N} X_i = \frac{X_1 + X_2 + ... + X_N}{N}$$

Formula kaže sljedeće: potrebno je zbrojiti sve opažene vrijednosti, tj. $X_i$ za svaki slučaj $i$ od prvog do zadnjeg, a zatim dobiveni zbir podijeliti s ukupnim brojem opažanja označenim sa $N$. Simbol $\sum$ (velika grčka slova sigma) označava operaciju sumacije, tj. zbrajanja, a izraz $\sum_{i=1}^{N} X_i$ doslovno znači "zbroji sve vrijednosti $X_i$ počevši od $i = 1$ pa sve do $i = N$". Student koji se prvi put susreće s ovom notacijom ne bi trebao biti obeshrabren jer se radi o formalnom matematičkom zapisu onoga što intuitivno već razumije iz svakodnevnog iskustva s računa prosjeka.

Razmotrimo praktičan primjer s empirijskim podacima. Pretpostavimo da su prikupljeni podaci o dnevnoj gledanosti Dnevnika HRT-a za jedan tjedan, što čini sedam opservacija: 315.000 gledatelja u ponedjeljak, 298.000 u utorak, 322.000 u srijedu, 305.000 u četvrtak, 288.000 u petak, 245.000 u subotu i 218.000 u nedjelju. Prosječna gledanost tada iznosi:

$$\bar{X} = \frac{315.000 + 298.000 + 322.000 + 305.000 + 288.000 + 245.000 + 218.000}{7} = \frac{1.991.000}{7} \approx 284.429$$

U statističkom programu R se aritmetička sredina izračunava primjenom funkcije `mean()`. Sljedeći kod demonstrira kako se ovaj izračun provodi na konkretnim podacima o gledanosti te kako se rezultat vizualizira kroz grafički prikaz.

```r
# Podatci o gledanosti Dnevnika HRT-a (u tisućama)
dani <- c("Pon", "Uto", "Sri", "Čet", "Pet", "Sub", "Ned")
gledanost_hrt <- c(315, 298, 322, 305, 288, 245, 218)

# Izračun aritmetičke sredine
prosjek <- mean(gledanost_hrt)

df_gledanost <- data.frame(
  dan = factor(dani, levels = dani),
  gledanost = gledanost_hrt
)

ggplot(df_gledanost, aes(x = dan, y = gledanost)) +
  geom_col(fill = "gray40", color = "black", width = 0.7) +
  geom_hline(yintercept = prosjek, linetype = "dashed", linewidth = 1) +
  annotate("text", x = 6.5, y = prosjek + 12,
           label = paste("Prosjek =", round(prosjek, 1), "tisuća"),
           size = 3.5, fontface = "bold") +
  labs(
    title = "Gledanost Dnevnika HRT-a tijekom tjedna",
    x = "Dan u tjednu",
    y = "Gledanost (tisuće)"
  ) +
  ylim(0, 350)
```

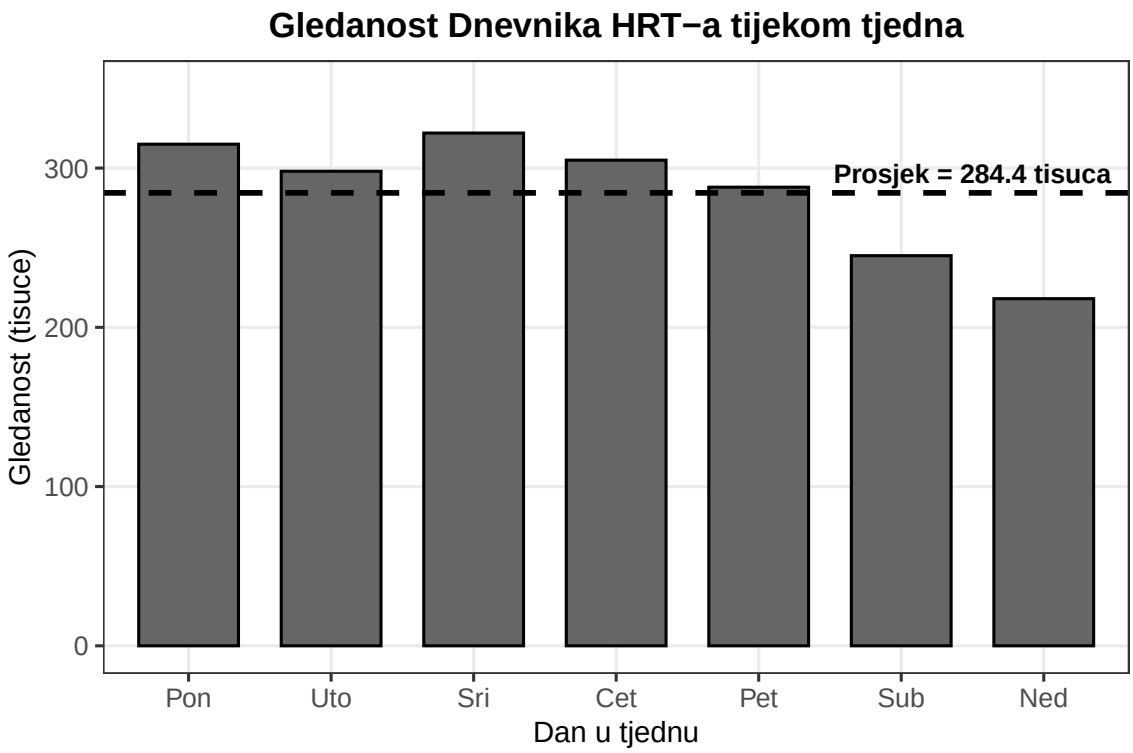


Figure 1: Dnevna gledanost Dnevnika HRT-a s označenim prosjekom. Isprekidana horizontalna linija označava aritmetičku sredinu, tj. prosječnu gledanost tijekom tjedna. Uočljivo je da gledanost vikendima pada znatno ispod prosjeka, što utječe na ukupnu srednju vrijednost.

Prosječna gledanost Dnevnika tijekom analiziranog tjedna bila je približno 284.000 gledatelja, što daje istraživaču medija brzu informaciju o općoj razini uspješnosti programa i omogućuje usporedbu s drugim tjednima ili s gledanošću konkurentskih programa. Međutim, sama vrijednost prosječne gledanosti ne govori ništa o konzistentnosti ili stabilnosti gledanosti tijekom tjedna – ne može se na temelju samog prosjeka zaključiti jesu li sve dnevne vrijednosti bile blizu te srednje vrijednosti ili su neke znatno veće a druge markantno manje. Vidljivo je, primjerice, da znantna razlika između vikenda (kada je gledanost značajno niža) i radnih dana (kada je gledanost viša) utječe na konačnu percepciju "tipične" gledanosti i može dovesti do iskrivljene predstave o realnom stanju.

Aritmetička sredina posjeduje važno matematičko svojstvo – ona predstavlja svojevrsno "težište" ili "ravnotežnu točku" podataka, tj. vrijednost oko koje su odchiljenji jednako raspoređeni prema obje strane. Ako se zamisli histogram podataka kao fizički čvrst objekt s masom proporcionalnom broju opservacija u svakoj vrijednosti, aritmetička sredina bila bi točka na kojoj bi se taj objekt mogao savršeno balansirati bez naginjanja. U tom dubokom smislu, aritmetička sredina ima centralno matematičko značenje: ona je vrijednost oko koje su podaci "organizirani" ili "centralizirani" na način da su ukupna pozitivna odstupanja i ukupna negativna odstupanja u savršenoj ravnoteži. Upravo ovo svojstvo čini aritmetičku sredinu iznimno osjetljivom na **ekstremne vrijednosti**, tj. vrijednosti koje su neuobičajeno

i bitno udaljene od ostatka distribucije podataka i koje se u statističkom jeziku nazivaju *outlierima*. Ako u skupu gledanosti postoji jedan neuobičajeno atipičan dan, primjerice dan kada je emitiran poseban ili viralni prilog o nekom izuzetno praćenom događaju ili katastrofi, ta pojedinačna vrijednost značajno utječe i "povlači" prosjek prema sebi. Aritmetička sredina, budući da koristi sve dostupne informacije iz svakog podatka, ne zanemarujući nijednu opservaciju, što može biti velika metodološka prednost, istovremeno znači da je mjera izrazito osjetljiva na ekstremne vrijednosti koje možda ne reprezentiraju niti tipičnu niti reprezentativnu situaciju u većini opservacija.

#### 0.1.1.2 Medijan

**Medijan** može se definirati kao mjera centralne tendencije koja predstavlja točnu srednju vrijednost kada se svi podaci poredaju ili sortiraju od najmanjega prema najvećem numeričkom redoslijedu. Koncept medijana možda je intuitivno čak jasniji od aritmetičke sredine jer se oslanja samo na informaciju o poziciji vrijednosti u poretku. Zamislimo podatke o dnevnom broju objava na stranici Jutarnjeg lista na društvenim mrežama tijekom jednog tjedna, tj. sedam dnevnih opservacija: 12, 8, 15, 10, 9, 14 i 11 objava. Da bi se pronašao medijan, prvim je korakom sortirati ove brojeve u rastući numerički niz: 8, 9, 10, 11, 12, 14, 15. Sada je očito da je vrijednost 11 objava smještena točno u sredini – tri vrijednosti su manje od nje, a tri su veće od nje.

Za razliku od aritmetičke sredine, medijan nije osjetljiv na ekstremne vrijednosti budući da se koristi samo informacija o poziciji vrijednosti u sortiranom nizu, ne o stvarnoj numeričkoj veličini tih vrijednosti. Medijan jednostavno i elegantno "ignorira" koliko su ekstremne krajnje vrijednosti – on gleda samo koja vrijednost dijeli podatke na dva jednaka dijela, tj. polovicu podataka manji od medijana i polovicu veću od medijana.

Formalno se medijan za skup od $N$ opservacija sortiranih u rastući niz definira na sljedeći način: ako je $N$ neparan broj, medijan je vrijednost koja se nalazi na poziciji $(N+1)/2$; ako je $N$ paran broj, medijan se izračunava kao aritmetička sredina dviju srednjih vrijednosti, tj. kao prosjek vrijednosti na pozicijama $N/2$ i $(N/2)+1$. U ovom drugom slučaju, medijan nije nužno jedna od stvarnih vrijednosti iz izvornog skupa podataka, već interpolirana vrijednost između njih.

$$\text{Medijan} = \begin{cases} X_{(N+1)/2} & \text{ako je } N \text{ neparan broj} \\ \frac{X_{N/2}+X_{(N/2)+1}}{2} & \text{ako je } N \text{ paran broj} \end{cases}$$

U statističkom programu R se medijan izračunava funkcijom `median()`. Razmotrimo konkretni primjer s HRT Playerom gdje se analizira broj pregleda za deset najpopularnijih emisija prošlog mjeseca. Većina emisija ima između 15.000 i 25.000 pregleda, što čini razumnu osnovnu distribuciju, ali jedna emisija – ekskluzivni intervju s istaknutom javnom osobom ili važnim političkim eventos – ima čak 180.000 pregleda, što je drastično više. Podaci sortirani od najmanjega prema najvećem broju pregleda su: 14.000, 16.000, 18.000, 19.000, 22.000, 23.000, 24.000, 26.000, 28.000 i 180.000.

```r
# Podatci o pregledima emisija na HRT Playeru (u tisućama)
pregledi_player <- c(14, 16, 18, 19, 22, 23, 24, 26, 28, 180)
emisije <- paste("Emisija", 1:10)

# Izračun sredine i medijana
sredina <- mean(pregledi_player)
medijan <- median(pregledi_player)

df_player <- data.frame(
  emisija = factor(emisije, levels = emisije),
  pregledi = pregledi_player,
  tip = ifelse(pregledi_player == 180, "Outlier", "Tipična")
)

ggplot(df_player, aes(x = emisija, y = pregledi, fill = tip)) +
  geom_col(color = "black", width = 0.7) +
  scale_fill_manual(values = c("Outlier" = "gray70", "Tipična" = "gray40")) +
  geom_hline(yintercept = sredina, linetype = "dashed", linewidth = 0.8) +
  geom_hline(yintercept = medijan, linetype = "solid", linewidth = 0.8) +
  annotate("text", x = 2.5, y = sredina + 8,
           label = paste("Prosjek =", sredina), size = 3) +
  annotate("text", x = 2.5, y = medijan + 8,
           label = paste("Medijan =", medijan), size = 3) +
  labs(
    title = "Pregledi emisija na HRT Playeru",
    subtitle = "Emisija 10 je outlier (viralni intervju s 180.000 pregleda)",
    x = "",
    y = "Pregledi (tisuće)"
  ) +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    legend.title = element_blank()
  )
```

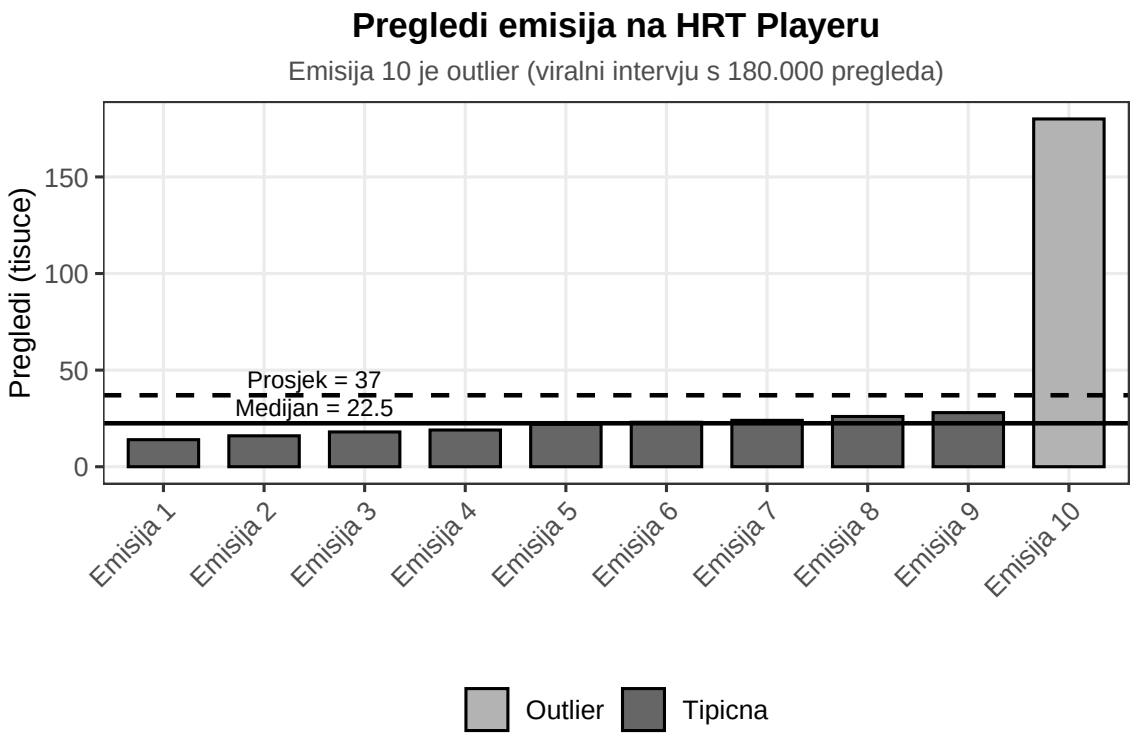


Figure 2: Usporedba aritmetičke sredine i medijana u prisutnosti outliera. Isprekidana linija označava aritmetičku sredinu, a puna linija medijan. Uočava se kako jedna ekstremna vrijednost (Emisija 10 s 180.000 pregleda) značajno povlači prosjek prema gore, dok medijan ostaje stabilan i bolje odražava tipičnu gledanost.

Ako se izračuna aritmetička sredina ovih deset vrijednosti, dobiva se $(14.000 + 16.000 + 18.000 + 19.000 + 22.000 + 23.000 + 24.000 + 26.000 + 28.000 + 180.000)/10 = 37.000$ pregleda. Ova brojka stvara pogrešan i iskrivljen dojam da je "tipična" emisija daleko popularnija nego što je stvarno u praksi budući da je jedna viralna emisija značajno povećala prosjek. Medijan se, s druge strane, izračunava kao prosjek pete i šeste vrijednosti (jer je broj opservacija paran): $(22.000 + 23.000)/2 = 22.500$ pregleda. Ovaj rezultat daleko bolje i autentičnije odražava tipičnu gledanost na platformi jer potpuno ignorira činjenicu da postoji jedna singularna emisija s 180.000 pregleda, tj. ekstremna vrijednost koja je artefakt specifičnog događaja. Medijan govori nam da će polovina emisija imati manje od 22.500 pregleda, a polovina više, što je bolji opis stvarne situacije na kanalu.

Medijan je stoga posebno koristan i preporučljiv u situacijama kada su podaci poznati ili sumnjivi da sadrže ekstremne vrijednosti, tj. outliere, kada je distribucija podataka poznato asimetrična ili iskrivljena, kada se želi utvrditi "tipična" vrijednost koja nije pod iskrivljenim utjecajem ekstremnih slučajeva, ili kada se koriste ordinalni podaci kod kojih numeričke vrijednosti možda nisu smislene za izračunavanje aritmetičkog prosjeka. Za istraživača masovne komunikacije, izbor između aritmetičke sredine i medijana kao reprezentativne mjere ovisi o vrsti i kvaliteti podataka te o specifičnom kontekstu istraživanja i postavljenim pitanjima. Ako je cilj istraživanja razumjeti ukupnu količinu angažmana

ili ukupni "teret" nekog fenomena u agregaciji, aritmetička sredina može biti metodološki primjerenija. Međutim, ako je cilj utvrditi što je "tipično" za većinu ili za reprezentativnu opservaciju, a posebno ako se sumnja ili zna da su podaci kontaminirani ekstremnim vrijednostima, medijan je često bolji i pouzdaniji izbor. U praksi istraživanja masovne komunikacije, iskusni i metodološki pažljivi istraživači često izvještavaju obje mjere budući da svaka od njih otkriva drugačiji i komplementaran aspekt podataka.

#### 0.1.1.3 Mod

**Mod** može se definirati kao najjednostavnija mjera centralne tendencije za operacionalizaciju – to je vrijednost koja se pojavljuje ili pojavi najčešće ili s najvećom frekvencijom u skupu podataka. Za razliku od aritmetičke sredine i medijana koji zahtijevaju numeričke podatke i računske operacije, mod se može primjenjuje na bilo koju vrstu podataka, uključujući i **kategorijske**, tj. **nominalne podatke** gdje brojevi nemaju inherentnu numeričku vrijednost. Ova karakteristika čini mod posebno korisnim i primjenjivim u komunikološkim istraživanjima gdje se često radi s nominalnim mjerilima, poput vrste medija, žanra sadržaja, tematske kategorije ili druge kvalitativne kategorije.

Razmotrimo konkretan i praktičan primjer. Analitičar sadržaja istražuje dominantne teme ili fokuse u večernjim vijestima RTL-a tijekom mjesec dana, tj. trideset emisija. Za svaku emisiju zabilježena je koja je tema dominirala ili bila nosioca tog dana. Podaci pokazuju sljedeću distribuciju frekvencija: politika se pojavila kao dominantna tema 12 puta, gospodarstvo 5 puta, kriminal 8 puta, zdravstvo 3 puta, a sport samo 2 puta. U ovom slučaju, mod je "politika", budući da se ta kategorija pojavljuje najčešće ili s najvećom frekvencijom od svih kategorija. Valja napomenuti da je potpuno nemoguće izračunati aritmetičku sredinu niti medijan za ovu vrstu podataka – pojmovi poput "prosjeka" između politike i gospodarstva jednostavno nemaju nikakvo smisleno značenje ako radimo s nominalnim kategorijama koje nemaju inherentno uređenje. Međutim, mod pruža korisnu i direktnu informaciju: najčešća tema u analiziranom periodu bila je politika, što može imati važne implikacije za razumijevanje medijske agende i distribucije sadržaja.

```r
# Podatci o dominantnim temama u vijestima RTL-a
teme_data <- data.frame(
  tema = c("Politika", "Kriminal", "Gospodarstvo", "Zdravstvo", "Sport"),
  frekvencija = c(12, 8, 5, 3, 2)
)

# Sortiranje prema frekvenciji
teme_data <- teme_data[order(-teme_data$frekvencija), ]
teme_data$tema <- factor(teme_data$tema, levels = teme_data$tema)

ggplot(teme_data, aes(x = tema, y = frekvencija)) +
  geom_col(fill = "gray40", color = "black", width = 0.7) +
  geom_text(aes(label = frekvencija), vjust = -0.5, size = 4) +
  labs(
```

```
    title = "Dominantne teme u večernjim vijestima RTL-a (30 dana)",
    subtitle = "Mod = Politika (najčešća tema)",
    x = "Tema",
    y = "Broj emisija"
  ) +
  ylim(0, 15)
```

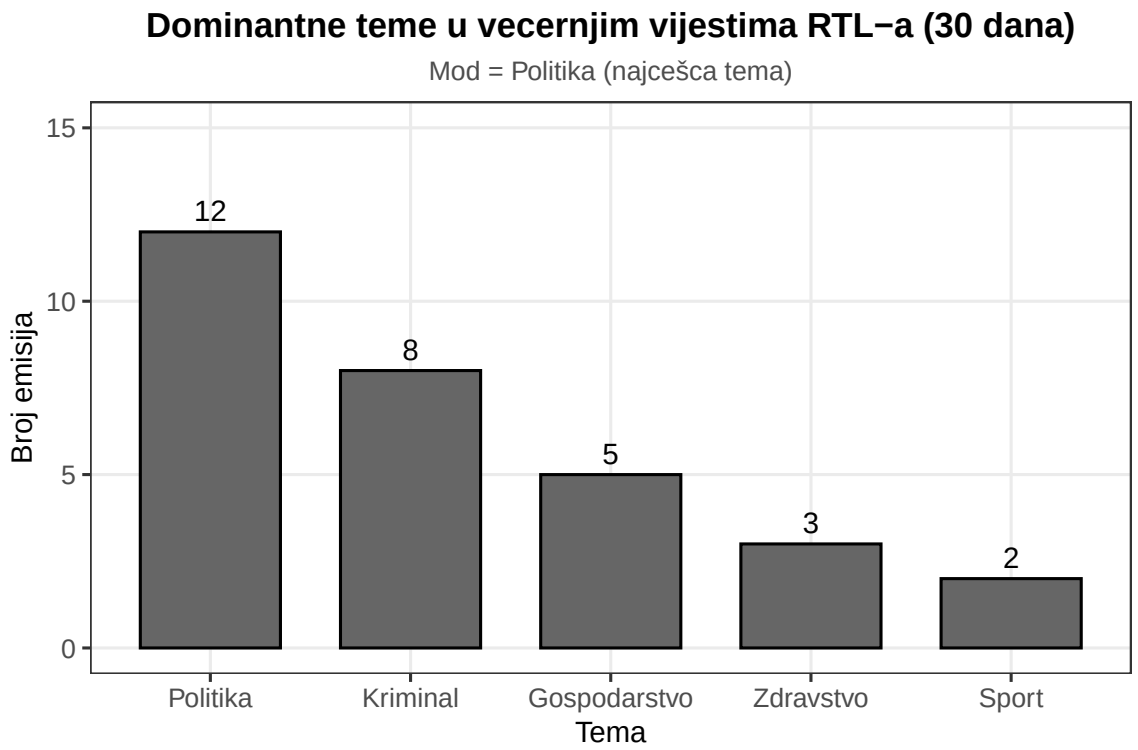


Figure 3: Distribucija dominantnih tema u večernjim vijestima RTL-a. Mod je 'Politika' jer se ta kategorija pojavljuje najčešće (12 od 30 emisija). Za nominalne varijable poput tematske kategorije, mod je jedina smislena mjera centralne tendencije.

Mod je jednako vrijedan i informativan za numeričke podatke, pogotovo u situacijama gdje je potrebno utvrditi "najvjerojatniju" ili "najčešće susretanu" vrijednost. Zamislimo da se analizira trajanje video clipova na YouTube kanalu popularne hrvatske medijske kuće ili portala. Iako postoji velika varijabilnost u trajanju videa, raspinući se od 30 sekundi do 15 minuta, primjećuje se da određene duljine ili intervali prevladavaju u praksi. Pretpostavimo da je analizirano sto videa i da nalazi pokazuju da 35 videa traje 2 minute, 20 videa traje 3 minute, 15 videa traje 1 minutu, 12 videa traje 5 minuta, 10 videa traje 4 minute, a ostalih 8 videa ima različita i raznovrsna druga trajanja. U ovom slučaju, mod je 2 minute budući da se ta vrijednost pojavljuje u čak 35 od 100 slučajeva ili opservacija. Ova informacija može biti vrijedna i instruktivna za razumijevanje uređivačke politike i prednosti platforme – očito postoji jaka redakcijska ili algoritmijska preferencija za videima koji traju točno

2 minute, što može reflektirati učinkovitost tog formata za angažman publ ili organsku distribuciju.

Zanimljivo je primijetiti da, za razliku od aritmetičke sredine i medijana koje uvijek imaju samo jednu vrijednost, skup podataka može imati **više modova** ili biti **multimodalan**. Ako se dvije ili više vrijednosti pojavljuju jednako često i češće od svih ostalih vrijednosti, tada se govori o **bimodalnoj** distribuciji (kada su dva moda) ili **multimodalnoj** distribuciji (kada je više modova). Takve situacije, iako kompleksnije, mogu biti vrlo informativne za interpretaciju podataka. Primjerice, ako analiza duljine članaka na nekom informativnom portalu pokazuje da postoje dva jasna moda, jedan oko 300 riječi i drugi oko 1200 riječi, to ukazuje na postojanje dviju strukturalno različitih i zasebnih vrsta sadržaja unutar portala: kratke vijesti i dugačke analitičke članke. Ovakav uvid mogao bi lako promaknuti analitičaru koji bi se razmatrao samo aritmetičku sredinu, budući da bi ta vrijednost bila negdje između ova dva moda i ne bi reprezentirala niti jednu grupu.

Međutim, valja biti svjestan i ograničenja moda kao mjere centralne tendencije. Mod može biti vrlo nestabilan ili varijabilan, pogotovo pri radu s kontinuiranim numeričkim podacima gdje se svaka vrijednost pojavljuje samo jednom ili nekoliko puta u manjim uzorcima, čime mod postaje arbitraran ili nepouzdan. Osim toga, mod ne govori ništa o "sredini" distribucije u širem teorijskom smislu – on jednostavno indicira koja je vrijednost najčešća. U nekim slučajevima, mod može biti prilično udaljen od onoga što bi se intuitivno smatralo "tipičnom" vrijednosti iz cjelokupne perspektive. Stoga se mod u praksi istraživanja masovne komunikacije često koristi u kombinaciji ili tandesku s drugim mjerama centralne tendencije kako bi se dobila sveobuhvatnija slika. U statističkom programu R ne postoji ugrađena funkcija namjenjeno samo izračunu moda, ali se on može jednostavno utvrditi ili identificirati pomoću funkcija `table()` i `which.max()`, koje identificiraju najčešću ili modalnu vrijednost u vektoru podataka.

#### 0.1.1.4 Izbor odgovarajuće mjere

Izbor odgovarajuće mjere centralne tendencije kao reprezentativne vrijednosti za konkretnu analizu ovisi o tri ključna i međuzavisna čimbenika: vrsti podataka ili razini mjerenja, prirodi i obliku distribucije tih podataka te konkretnome istraživačkom pitanju na koje se želi odgovoriti. S obzirom na to da je razumijevanje mjernih razina detaljno obrađeno u poglavlju 3 (Nacrt istraživanja), ovdje se daje samo sažeti pregled koji je relevantan za praktičan izbor mjere.

Vrsta podataka ili **razina mjerenja** predstavlja prvi i najvažniji kriterij u ovom procesu izbora. Za **nominalne podatke**, tj. kategorije bez inherentnog ili prirodnog redoslijeda, kao što su vrsta medija (televizija, radio, novine, internet), žanr sadržaja (vijesti, zabava, sport, kultura) ili kategorija emitenta, jedino je mod smislena i održiva opcija. Pojmovi kao što su "prosjek" ili "sredina" nemaju značenje ili nisu primjenjivi kada se govori o kategorijama koje nemaju numeričku vrijednost. Za **ordinalne podatke**, tj. kategorije ili razrede koje imaju prirodni i intuitvno razumljiv redoslijed, ali ne i jednake intervale između njih, preferira se ili je preporučljiva **medijan**. Primjer ordinalnih podataka u komunikološkom istraživanju su ocjene na Likertovoj skali, o kojoj je bilo riječi u poglavlju 3, gdje ispitanici procjenjuju

ili stupnjevalno određuju koliko često prate vijesti na skali od "nikada" (1) do "uvijek" (5). Medijan koristi samo informaciju o redoslijedu vrijednosti, što ga čini intrinzički prikladnim za ordinalne podatke budući da ne preuzima pretpostavku o jednakim intervalima. Međutim, u praksi istraživanja masovne komunikacije mnogi istraživači i autori ipak izračunavaju aritmetičke sredine Likertovih skala, što je predmet kontinuirane metodološke debate i kritike među statističkim pedagozima. Za **intervalne i omjerne podatke**, tj. podatke s pravim numeričkim vrijednostima i smislenim intervalima između vrijednosti ili čak omjerima, postoji najveća metodološka fleksibilnost i izbor. Ako je distribucija podataka relativno simetrična i bez znantnih ekstremnih vrijednosti ili outliera, preferira se aritmetička sredina budući da koristi sve dostupne informacije u podacima i posjeduje bolja matematička svojstva. Međutim, ako distribucija pokazuje značajnu asimetriju ili sadrži znantne i teško objašnjive ekstremne vrijednosti, medijan može pružiti vjerodostojniju i reprezentativniju sliku o "tipičnoj" vrijednosti.

Razmotrimo konkretan praktičan primjer koji ilustrira ovaj izbor i njegove implikacije. Analitičar ili istraživač istražuje učinkovitost i utjecaj društvenih mreža za promociju sadržaja popularne stranice Index.hr. Prikupio je podatke o broju klikova koje je generirala stotina Facebook objava tijekom mjeseca dana. Većina objava generirala je između 500 i 2000 klikova, što odražava uobičajenu, očekivanu razinu angažmana. Međutim, tri objave su postale viralne i generirale su 45.000, 52.000 i 68.000 klikova, što je drastično veće od tipične vrijednosti. Ako se izračuna aritmetička sredina, te tri viralne objave značajno povećavaju prosjek, možda na 3500 klikova. Ova brojka stvara pogrešan dojam o tome što portal može "tipično" ili "realno" očekivati od Facebook promocije za prosječnu objavu. S druge strane, medijan bi bio vjerojatno oko 1200 klikova, što bolje odražava uobičajeni scenarij i stvarne iskustvo većine objava. U ovoj situaciji, iskusni i metodološki svjesni istraživač bi vjerojatno izvijestio obje vrijednosti, jasno objašnjavajući da je medijan bolji pokazatelj "tipične" uspješnosti promocije, dok aritmetička sredina odražava ukupni prosjek uključujući rijetke ali vrlo uspješne viralne objave. U praksi kvalitetnog istraživanja masovne komunikacije, često je metodološki korisno izvijestiti više mjera centralne tendencije budući da svaka otkriva različite i komplementarne aspekte podataka. Ne postoji univerzalno "najbolja" mjera, a izbor zahtijeva promišljeno i stručno razmatranje prirode podataka, distribucije i specifičnog istraživačkog konteksta.

Sljedeća tablica sažima preporuke za izbor mjere centralne tendencije s obzirom na vrstu podataka.

Table 1: Preporuke za izbor mjere centralne tendencije prema vrsti podataka. Ključni uvit iz ove tablice jest da vrsta mjernog instrumenta, tj. razina mjerenja, određuje koje su mjere uopće smislene, dok oblik distribucije određuje koja je od smislenih mjera najprikladnija.

| Vrsta podataka | Preporučena mjera | Alternativa | Funkcija u R-u | Napomena |
|---|---|---|---|---|
| Nominalni | Mod | – | `table()` + `which.max()` | Jedina smislena opcija |

| Vrsta podataka | Preporučena mjera | Alternativa | Funkcija u R-u | Napomena |
|---|---|---|---|---|
| Ordinalni | Medijan | Mod | `median()` | Aritmetička sredina upitna |
| Intervalni/Omjerni (simetrični) | Aritmetička sredina | Medijan | `mean()` | Obje prihvatljive |
| Intervalni/Omjerni (asimetrični) | Medijan | Aritmetička sredina | `median()` | Oprez s outlierima |

Nakon što je utvrđeno kako se opisuje "središte" podataka, sljedeće logično pitanje koje se postavlja jest koliko su podaci raspršeni ili varijabilni oko tog središta. Upravo time bave se mjere disperzije ili varijabilnosti.

### 0.1.2 Mjere disperzije

**Mjere centralne tendencije** govore samo dio priče ili prikaza podataka – one pokazuju "sredinu" ili reprezentativnu vrijednost, ali ne govore ništa važno o tome koliko su ti podaci raspršeni, varijabilni ili disperzivni oko te sredine. Analitičar portala Index.hr koji pregledava podatke o dnevnom broju posjeta stranici tijekom mjeseca dana primjećuje da je prosječna dnevna posjećenost bila 850.000 korisnika. Ova informacija zvuči početno korisno, ali kad se promisli dublje i kritički, postaje jasno da nedostaje ključni dio slagalice ili slika. Naime, radi li se o portalu čija je posjećenost svaki dan ili gotovo svaki dan približno 850.000, što bi ukazivalo na izuzetno stabilnu, predvidivu i konzistentnu publiku? Ili je možda većinu dana posjećenost oko 600.000 korisnika, ali ponekad dosegne 1.500.000 kada portal objavi posebno atraktivnu ili kontroverznu priču ili kada se desi neki značajan društveni događaj? Ova dva scenarija imaju potpuno različite i suprotne implikacije za razumijevanje karakteristika publike i za planiranje sadržaja i promidbe, iako oba mogu imati identičan prosjek od 850.000. Razlika je fundamentalna i ima praktične posljedice.

Upravo u tom kritičnom trenutku postaju neophodne **mjere disperzije** ili **mjere varijabilnosti**. Ove statističke mjere kvantificiraju, mjere i izražavaju koliko su podaci "rasprostranjeni" ili "razasuti" oko centrale vrijednosti, tj. koliko tipično ili u prosjeku stvarne opservacije odstupaju od reprezentativne vrijednosti. Za istraživača masovne komunikacije, ova informacija o varijabilnosti može biti jednako važna, ako ne i važnija, od samog prosjeka ili srednje vrijednosti. U nastavku se obrađuju četiri glavne i najčešće korištene mjere disperzije: raspon, međukvartilni raspon, varijanca i standardna devijacija.

#### 0.1.2.1 Raspon

**Raspon** predstavlja najjednostavniju mjeru disperzije i definira se kao direktna razlika između maksimalne (najveće) i minimalne (najmanje) vrijednosti u skupu podataka. Ako

analitičar istražuje trajanje televizijskih reklama na HRT-u i utvrdi da je najkraća reklama trajala 10 sekundi, a najdulja 90 sekundi, raspon iznosi $90 - 10 = 80$ sekundi. Ova brojka odmah daje istraživaču brz osjećaj ili intuiciju koliko velika je disperzija ili razina varijabilnosti u trajanju reklama. U statističkom programu R se raspon može izračunati pomoću funkcija `range()`, koja vraća vektor s dva elementa – minimumom i maksimumom – ili izravno kao numerička vrijednost `max(x) - min(x)`.

Privlačnost raspona leži u njegovoj ekstremnoj jednostavnosti i brz izračunljivosti – ne može biti lakše ili direktnije za izračunati, a interpretacija je potpuno jasna i intuitivna. Međutim, upravo ta elementarna jednostavnost krije ozbiljan i važan nedostatak ili ograničenje. Pretpostavimo da se analizira sto reklama i da devedeset i devet od njih traje između 25 i 35 sekundi, što ukazuje na izuzetno konzistentno, homogeno trajanje. Međutim, postoji jedna neobična ili iznimna reklama, možda poseban promotivni spot ili viralni snimak, koja traje 90 sekundi. Raspon cijelog skupa podataka i dalje iznosi $90 - 25 = 65$ sekundi, što stvara dojam velike varijabilnosti, iako je 99% reklama, tj. gotovo sva reklama, u vrlo uskom rasponu od samo 10 sekundi. Ovaj primjer sjajno ilustrira ključni problem s rasponom kao mjerom: on je potpuno **nerobusna** mjera, tj. izuzetno je osjetljiv na outliere, tj. ekstremne vrijednosti. Potrebna je samo jedna ekstremna vrijednost da bi raspon dao potpuno iskrivljenu ili pogrešnu sliku o disperziji stvarnih podataka. Osim toga, raspon koristi samo dvije vrijednosti iz cijelog skupa podataka – minimum i maksimum – potpuno ignorirajući sve ostale informacije koje su dostupne od stotinu ostalih opservacija.

#### 0.1.2.2 Međukvartilni raspon (IQR)

**Međukvartilni raspon** (engl. *Interquartile Range*, skraćeno IQR) elegantno rješava ili mitiga problem osjetljivosti na outliere. Umjesto razlike između apsolutnih ekstrema ili krajnjih vrijednosti, IQR mjeri razliku između vrijednosti koje su "prilično visoke" i "prilično niske", konkretno između trećeg i prvog kvartila.

**Kvartili** dijele sortiran skup podataka na četiri jednaka ili ekvivalentna dijela. **Prvi kvartil** ($Q_1$ ili 25. percentil) je vrijednost takva da se točno 25% podataka nalazi ispod nje, a 75% iznad nje. **Treći kvartil** ($Q_3$ ili 75. percentil) je vrijednost takva da se 75% podataka nalazi ispod nje, a 25% iznad nje. Medijan je zapravo **drugi kvartil** ($Q_2$ ili 50. percentil) koji smo već razmatrali. **Međukvartilni raspon** definira se kao direktna razlika trećeg i prvog kvartila:

$$IQR = Q_3 - Q_1$$

Drugim riječima, IQR mjeri raspon ili raspon "srednje polovice" podataka, tj. raspon ili interval unutar kojeg se nalaze točno srednja polovica ili 50% opservacija. Ova mjera elegantno i automatski eliminira ili ignoriora gornju i donju četvrtinu podataka ili 25% krajnjih vrijednosti s obje strane, čime automatski i neusljedno eliminira utjecaj ekstremnih vrijednosti. U statističkom programu R se IQR izračunava funkcijom `IQR()`, a pojedini kvartili se mogu dobiti pomoću funkcije `quantile()`.

Vratimo se primjeru s portalom Index.hr. Pretpostavimo da analitičar istražuje broj komentara ili interakcija na člancima objavljenim tijekom mjeseca dana. Prikupljeni su podaci za dvadeset članaka i sortirani od najmanje prema najvećoj vrijednosti: 5, 8, 12, 15, 18, 22, 25, 28, 32, 35, 38, 42, 45, 50, 55, 62, 68, 75, 82 i 450. Primjećuje se da posljednji članak ima neobično velik broj komentara – 450, što je drastično više od ostalih – očito se radi o kontroverznoj temi koja je potakla veliku i bučnu raspravu.

```r
# Podatci o broju komentara na člancima Index.hr
komentari <- c(5, 8, 12, 15, 18, 22, 25, 28, 32, 35,
               38, 42, 45, 50, 55, 62, 68, 75, 82, 450)

df_komentari <- data.frame(komentari = komentari)

# Izračun kvartila i IQR-a
Q1 <- quantile(komentari, 0.25)
Q3 <- quantile(komentari, 0.75)
IQR_val <- IQR(komentari)
raspon <- max(komentari) - min(komentari)

ggplot(df_komentari, aes(x = "", y = komentari)) +
  geom_boxplot(fill = "gray80", color = "black", width = 0.4,
               outlier.shape = 1, outlier.size = 3) +
  geom_jitter(width = 0.08, alpha = 0.6, size = 2) +
  annotate("text", x = 1.35, y = Q1, label = paste("Q1 =", Q1), hjust = 0, size = 3) +
  annotate("text", x = 1.35, y = median(komentari),
           label = paste("Medijan =", median(komentari)), hjust = 0, size = 3) +
  annotate("text", x = 1.35, y = Q3, label = paste("Q3 =", Q3), hjust = 0, size = 3) +
  labs(
    title = "Broj komentara na člancima Index.hr",
    subtitle = paste("IQR =", IQR_val, " | Raspon =", raspon, "(raspon osjetljiv na outlie
    x = "",
    y = "Broj komentara"
  )
```

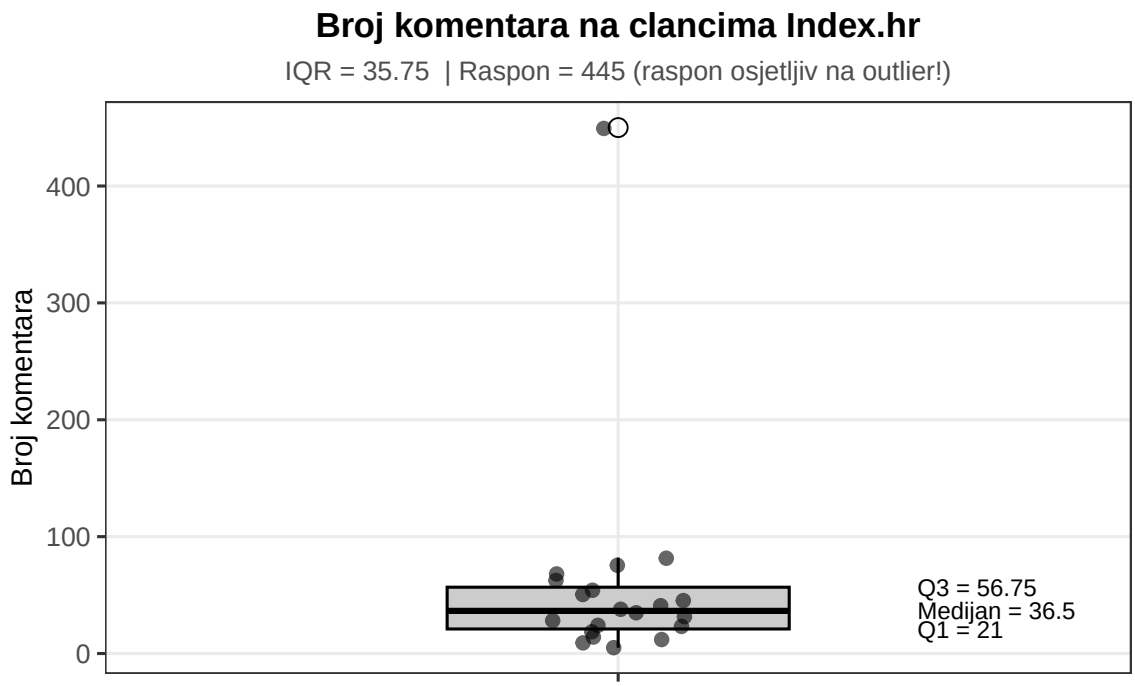


Figure 4: Box plot broja komentara na člancima portala Index.hr. Pravokutnik označava međukvartilni raspon (od Q1 do Q3), linija unutar njega je medijan, a kružić označava outlier. Uočava se kako IQR od 40 komentara daleko bolje odražava tipičnu varijabilnost nego raspon od 445, koji je iskrivljen jednim ekstremnim člankom.

Ako bi se izračunao raspon, dobilo bi se $450 - 5 = 445$ komentara, što daje faktički iskrivljenu sliku jer je većina članaka primila daleko manje komentara. Međukvartilni raspon pristupa problemu drugačije i sofisticiranije. Prvi kvartil $Q_1$ iznosi oko 20 komentara, treći kvartil $Q_3$ oko 60 komentara, pa je $IQR = 60 - 20 = 40$ komentara. Ova brojka ili vrijednost kaže nam da "srednja polovica" članaka varira za oko 40 komentara, što su manje ekstremne razlike, potpuno ignorirajući ili zaobilazeći članak s 450 komentara, koji je jasno outlier, i dajući realističniju, verodostojnu sliku o varijabilnosti "tipičnih" članaka. IQR je stoga idealan ili preporučljiv izbor kada se radi s podacima koji su poznati ili se sumnja da sadrže outliere ili ekstremne vrijednosti, što je česta i gotovo uobičajena situacija u analizi medijskih podataka gdje se nailazi na viralne objave, iznimno popularne članke, spektakularne klikove ili druge ekstremne i teško predvidive slučajeve.

#### 0.1.2.3 Varijanca i standardna devijacija

Za razliku od raspona i međukvartilnog raspona koji koriste samo nekoliko odabranih ili specifičnih vrijednosti, **varijanca** pristupa mjerenju disperzije na fundamentalno drugačiji,

holistički način budući da uzima u obzir sve dostupne opservacije i kvantificira koliko svaka od njih, u prosjeku, odstupa od prosjeka. Razmotrimo konkretni scenarij. Analitičar istražuje gledanost pet epizoda pojedine televizijske serije na HRT-u: 180.000, 165.000, 195.000, 170.000 i 190.000 gledatelja.

Prvi korak je izračunati aritmetičku sredinu: $\bar{X} = 180.000$ gledatelja. Zatim se za svaku epizodu izračunava koliko odstupa od prosjeka ili kako se odstupa od sredine, a to je odstupanje se kvadrira kako bi se eliminirali negativni predznaci i kako bi veća odstupanja bila važnija.

Table 2: Izračun varijance za gledanost TV serije. Varijanca se dobiva tako da se zbroje sva kvadrirana odstupanja i podijele s $N - 1$. Kvadriranje je potrebno jer bi se pozitivna i negativna odstupanja inače poništila, dajući uvijek zbroj nula.

| Epizoda | Gledatelji | Odstupanje od prosjeka | Kvadrirano odstupanje |
|---|---|---|---|
| 1 | 180.000 | 0 | 0 |
| 2 | 165.000 | -15.000 | 225.000.000 |
| 3 | 195.000 | 15.000 | 225.000.000 |
| 4 | 170.000 | -10.000 | 100.000.000 |
| 5 | 190.000 | 10.000 | 100.000.000 |

Varijanca se zatim izračunava kao prosjek ili srednja vrijednost kvadriranih odstupanja:

$$s^2 = \frac{1}{N-1} \sum_{i=1}^{N} (X_i - \bar{X})^2$$

Ova formula matematički kaže sljedeće: za svaku opservaciju, izračunaj razliku između te opservacije i prosjeka, tu razliku kvadriraj kako bi se uklonili negativni predznaci, zbroji sve takve kvadrirane razlike, te rezultat podijeli s $N - 1$. Dijeljenje s $N - 1$ umjesto $N$ koristi se zato što se u istraživanjima obično radi s uzorkom koji reprezentira veću populaciju, a ova korekcija, poznata kao **Besselova korekcija**, osigurava statističku nepristranost ili osigurava da je procjenitelj populacijske varijance pravi ili nepristran.[1]

Za naš primjer: $s^2 = (0 + 225.000.000 + 225.000.000 + 100.000.000 + 100.000.000)/4 = 162.500.000$. Varijanca gledanosti je 162,5 milijuna. Ali 162,5 milijuna čega? Ovdje se nailazi na fundamentalni problem ili neuspješnost varijance kao mjere: ona je izražena u **kvadratnim jedinicama** izvorne varijable mjerenja. Ako se mjere gledatelji, varijanca je u "gledatelji na kvadrat", što nema nikakvo realno, fizičko ili interpretabilno značenje i čini varijancu gotovo nemogućnom za izravnu interpretaciju u praksi. Unatoč ovom interpretativnom problemu, varijanca je matematički fundamentalna mjera i ima izvrsna svojstva koja je čine temeljem gotovo svih naprednih statističkih metoda – ona je aditivna (varijance nezavisnih varijabli se mogu zbrajati), elegantno se ponaša u teorijskim razmatranjima i ima bogata matematička svojstva. U statističkom programu R se varijanca izračunava funkcijom `var()`.

[1] Detaljnije objašnjenje zašto se dijeli s $N - 1$ umjesto $N$ daje se u poglavlju 9, u kontekstu razlikovanja statistika uzorka i parametara populacije.

**Standardna devijacija** rješava problem neinterpretabilnosti varijance jednostavnom i elegantnom matematičkom operacijom – uzimanjem kvadratnog korijena:

$$s = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N}(X_i - \bar{X})^2}$$

Drugim riječima, standardna devijacija je kvadratni korijen varijance, čime se matematički vraća na izvorne mjerne jedinice i čini vrijednost interpretabilnom. Za primjer gledanosti serije: $s = \sqrt{162.500.000} \approx 12.748$ gledatelja. Sada postoji broj koji se može razumjeti i smisleno komunicirati: standardna devijacija gledanosti je približno 12.750 gledatelja, što se može interpretirati kao mjera "tipičnog" ili "prosječnog" odstupanja od prosječne gledanosti od 180.000 gledatelja. U statističkom programu R se standardna devijacija izračunava funkcijom `sd()`.

Za interpretaciju standardne devijacije koristi se **empirijsko pravilo** (poznato i kao pravilo 68-95-99.7), koje vrijedi za približno simetrične, zvonoliko oblikovane distribucije poznate kao normalna ili Gaussova distribucija. Prema ovom praktičnom i empirijski potvrđenom pravilu, približno 68% podataka pada u raspon od jedne standardne devijacije oko prosjeka ($\bar{X} \pm 1s$), približno 95% podataka pada u raspon od dvije standardne devijacije ($\bar{X} \pm 2s$), a gotovo svi podaci, točnije 99.7%, padaju u raspon od tri standardne devijacije ($\bar{X} \pm 3s$).

```r
set.seed(123)
# Simulacija gledanosti 200 epizoda (u tisućama)
gledanost_serija <- rnorm(200, mean = 180, sd = 25)

prosjek_s <- mean(gledanost_serija)
sd_s <- sd(gledanost_serija)

# Provjera empirijskog pravila
u_1sd <- mean(gledanost_serija >= prosjek_s - sd_s &
              gledanost_serija <= prosjek_s + sd_s) * 100
u_2sd <- mean(gledanost_serija >= prosjek_s - 2*sd_s &
              gledanost_serija <= prosjek_s + 2*sd_s) * 100

df_serija <- data.frame(gledanost = gledanost_serija)

ggplot(df_serija, aes(x = gledanost)) +
  geom_histogram(aes(y = after_stat(density)), bins = 20,
                 fill = "gray60", color = "black") +
  geom_vline(xintercept = prosjek_s, linewidth = 1.2) +
  geom_vline(xintercept = c(prosjek_s - sd_s, prosjek_s + sd_s),
             linetype = "dashed", linewidth = 0.8) +
  geom_vline(xintercept = c(prosjek_s - 2*sd_s, prosjek_s + 2*sd_s),
             linetype = "dotted", linewidth = 0.8) +
  annotate("text", x = prosjek_s, y = 0.019, label = "M", size = 4, fontface = "bold") +
```

```
  annotate("text", x = prosjek_s - sd_s, y = 0.018, label = "-1SD", size = 3) +
  annotate("text", x = prosjek_s + sd_s, y = 0.018, label = "+1SD", size = 3) +
  annotate("text", x = prosjek_s - 2*sd_s, y = 0.017, label = "-2SD", size = 3) +
  annotate("text", x = prosjek_s + 2*sd_s, y = 0.017, label = "+2SD", size = 3) +
  labs(
    title = "Gledanost TV serije na HRT-u (200 epizoda)",
    subtitle = paste0("M = ", round(prosjek_s, 1), " | SD = ", round(sd_s, 1),
                      " | Unutar ±1SD: ", round(u_1sd), "% | Unutar ±2SD: ", round(u_2sd),
    x = "Gledanost (tisuće)",
    y = "Gustoća"
  )
```

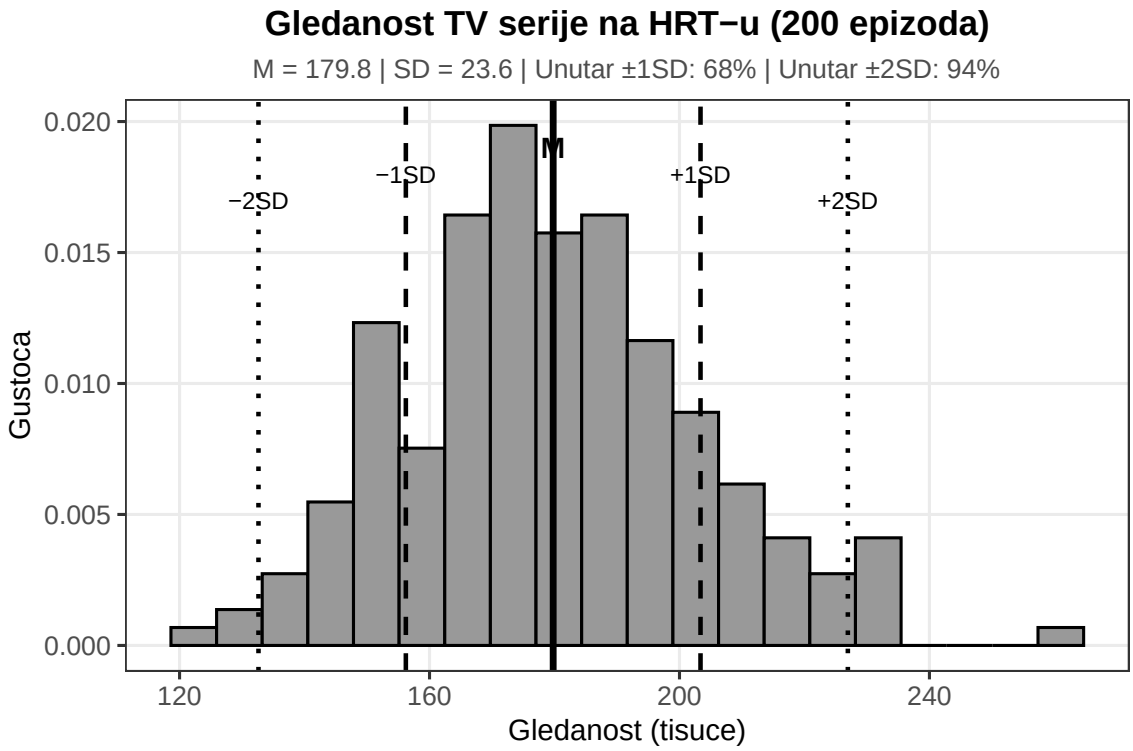


Figure 5: Demonstracija empirijskog pravila na simuliranim podacima o gledanosti TV serije (200 epizoda). Puna vertikalna linija označava prosjek, isprekidane linije granice jedne standardne devijacije, a točkaste linije granice dviju standardnih devijacija. Vidljivo je da većina podataka pada unutar jedne standardne devijacije od prosjeka.

Primijenimo ovo praktično pravilo na primjer s gledanošću serije. Prosječna gledanost je bila 180.000 gledatelja, a standardna devijacija je 12.750 gledatelja. Prema empirijskom pravilu, očekuje se da oko 68% epizoda ima gledanost između $180.000 - 12.750 = 167.250$ i $180.000 + 12.750 = 192.750$ gledatelja. Gotovo sve epizode, točnije oko 99.7%, trebale bi imati gledanost između $180.000 - 3 \times 12.750 = 141.750$ i $180.000 + 3 \times 12.750 = 218.250$

gledatelja. Epizoda s gledanošću koja pada izvan ovog širokog raspona od tri standardne devijacije predstavljala bi statistički neuobičajan, anomalan slučaj koji bi zahtijevao posebnu pažnju i interpretaciju analitičara.

Standardna devijacija ima posebnu vrijednost kada se žele usporediti ili komparirati različiti skupovi podataka ili različite varijable. Zamislimo da se uspoređuju dva informativna portala po njihovoj stabilnosti. Portal A ima prosječno 50.000 posjeta dnevno sa standardnom devijacijom od 5.000 korisnika, što pokazuje malenu varijabilnost. Portal B također ima prosječno 50.000 posjeta dnevno, ali sa standardnom devijacijom od 25.000 korisnika, što pokazuje veliku varijabilnost. Iako oba portala imaju identičan prosjek, portal A pokazuje daleko konzistentniju, predvidljiviju posjećenost, dok portal B pokazuje veliku varijabilnost ili nestabilnost, s danima koji su vrlo slabi i danima koji su izuzetno jaki ili viralni. Ova razlika u konzistentnosti ili predvidljivosti može imati važne i praktične implikacije za poslovne odluke, investicije, planiranje ili razumijevanje ponašanja publike.

#### 0.1.2.4 Usporedba mjera disperzije

Nakon pregleda četiriju glavnih mjera disperzije, korisno je razmotriti njihove redovite prednosti, nedostatke i primjenjivost u usporednom kontekstu. **Robusnost na outliere** predstavlja najvažniju razliku između mjera: raspon, varijanca i standardna devijacija su osjetljive na ekstremne vrijednosti budući da koriste sve podatke, dok je međukvartilni raspon vrlo robustan jer koristi samo "srednju polovicu". Raspon i međukvartilni raspon koriste samo nekoliko vrijednosti iz skupa podataka – minimum i maksimum za raspon, samo kvartile za IQR – dok varijanca i standardna devijacija koriste sve dostupne opservacije. Standardna devijacija ima najjednostavniju interpretaciju, koristi sve podatke i ima najbolju kombinaciju interpretabilnosti i matematičkih svojstava, što je čini najčešće korištenom mjerom disperzije u istraživačkoj praksi.

Table 3: Usporedba mjera disperzije. Ključni zaključak jest da ne postoji univerzalno najbolja mjera: međukvartilni raspon je najprikladniji kada podaci sadrže outliere, dok je standardna devijacija najčešći izbor za čiste podatke s približno simetričnom distribucijom. Stupac s R funkcijama pokazuje da se svaka od ovih mjera može izračunati jednim pozivom funkcije.

| Mjera | Robusnost na outliere | Koristi sve podatke | Interpretabilnost | Funkcija u R-u | Tipična primjena |
|---|---|---|---|---|---|
| Raspon | Vrlo slaba | Ne (samo 2 vrijednosti) | Visoka | `range()` | Brzi uvid u ekstreme |
| IQR | Vrlo jaka | Ne (samo kvartili) | Visoka | `IQR()` | Podaci s outlierima |
| Varijanca | Slaba | Da | Niska (kvadratne jedinice) | `var()` | Teorijske analize |

| Mjera | Robusnost na outliere | Koristi sve podatke | Interpretabilnost | Funkcija u R-u | Tipična primjena |
|---|---|---|---|---|---|
| Standardna devijacija | Slaba | Da | Visoka | `sd()` | Univerzalna mjera |

Valja biti svjestan važne konvencije u izvještavanju rezultata: mjere centralne tendencije i mjere disperzije uvijek se izvještavaju ili se trebaju izvještati u parovima ili tandemima. **Aritmetička sredina** se uvijek navodi zajedno sa **standardnom devijacijom** jer obje koriste sve dostupne podatke i obje su osjetljive na outliere, čime čine kompatibilan par. **Medijan** se izvještava s **međukvartilnim rasponom** budući da obje mjere koriste informacije o poziciji vrijednosti u poretku i obje su robusne na outliere, čime čine drugi prikladan par. Primjer ispravnog izvještavanja jest: "Prosječan broj objava na dan bio je $M = 12.5$ ($SD = 3.2$)" ili "Medijan broja komentara bio je $Mdn = 45$ ($IQR = 23$)". Brojke se u društvenim znanostima i komunikološkim istraživanjima općenito zaokružuju na dvije decimale i uvijek se jasno kontekstualiziraju, objašnjavajući što znače u praktičnom kontekstu istraživačkog pitanja i barem na razini interpretacije.

Nakon što je utvrđeno kako se u deskriptivnoj analizi opisuju izvori vrijednost i raspršenost pojedinih varijabli, sljedeći logičan korak jest ispitati i razumjeti odnose ili korelacije između dviju ili više varijabli. Upravo to omogućuju standardizirani rezultati i korelacijska analiza.

### 0.1.3 Standardizirani rezultati i korelacije

Dosad obrađene mjere i pristup opisuju pojedinačne varijable isolirano – njihovu reprezentativnu vrijednost, njihovu disperziju i raspršenost. Međutim, u istraživanju masovne komunikacije rijetko zanima samo jedna izolirana varijabla ili fenomen sama po sebi. Umjesto toga, gotovo u svim praktičnim scenarijima želi se razumjeti i kvantificirati **odnose** ili **povezanosti** između varijabli ili fenomena. Je li veći angažman ili aktivnost na društvenim mrežama povezan s većom lojalnošću brendu ili proizvodu? Postoji li sistematska veza između duljine članka i broja komentara ili interakcije koje generiše? Kako se gledanost različitih televizijskih programa povezuje međusobno? Ova brojna i praktična pitanja zahtijevaju prijelaz s univarijatne analize (fokus na jednu varijablu) na bivarijatnu ili multivarijatnu analizu (fokus na dvije ili više varijabli zajedno). Međutim, prije nego što se mogu smisleno uspoređivati varijable koje su mjerene na različitim skalama ili s različitim mjernim jedinicama, potrebno je razumjeti koncept standardizacije ili normalizacije podataka.

#### 0.1.3.1 Z-vrijednosti

**Standardizirani rezultat** ili **z-vrijednost** može se definirati kao broj standardnih devijacija za koji određena opservacija ili pojedinačna vrijednost odstupa od prosjeka. Zamislimo sljedeći scenarij: komunikolog razvija novi upitnik ili instrument za mjerenje "sklonosti

dijeljenju dezinformacija" na društvenim mrežama. Upitnik sadrži 40 pitanja ili stavki, a sudionici odgovaraju na skali od 1 do 5 za svako pitanje, što znači da je mogući ili teoretski raspon rezultata od 40 do 200 bodova. Nakon provedbe istraživanja na uzorku od 10.000 korisnika društvenih mreža, prosječan rezultat je 110 sa standardnom devijacijom od 15 bodova. Osoba koja dobije rezultat od 145 bodova – kako bi se taj rezultat trebao interpretirati ili razumjeti?

Jedan mogući pristup bio bi reći da je osoba postigla 72.5% maksimalnog mogućeg rezultata (145/200). Međutim, ovaj pristup ne uzima u obzir ili ignoriše kako se zapravo ponašaju ostali ljudi u populaciji ili kako se rezultati distribuiraju. Bolji i informativniji pristup jest usporediti osobu s distribucijom rezultata u populaciji ili uzorku, što omogućuje formula za z-vrijednost:

$$z_i = \frac{X_i - \bar{X}}{s}$$

Ova formula matematički kaže: od sirove vrijednosti ($X_i$) potrebno je oduzeti prosjek populacije ($\bar{X}$) i rezultat podijeliti sa standardnom devijacijom ($s$) kako bi se dobila standardizirana vrijednost. Za navedenu osobu: $z = (145 - 110)/15 = 2.33$. Ova osoba je 2.33 standardne devijacije iznad prosjeka, što prema empirijskom pravilu znači da se nalazi u gornjih približno 1% populacije, tj. da je značajno neuobičajena ili ekstremna u smislu sklonosti dijeljenju dezinformacija. U statističkom programu R se z-vrijednosti izračunavaju funkcijom `scale()`, koja automatski centrira podatke oko nule i skalira ih na standardnu devijaciju od 1.

```
set.seed(456)
# Simulacija rezultata upitnika (N = 500)
rezultati <- rnorm(500, mean = 110, sd = 15)

# Standardizacija pomoću funkcije scale()
z_scores <- scale(rezultati)[,1]

posebna_osoba <- 145
z_posebna <- (posebna_osoba - mean(rezultati)) / sd(rezultati)

df_z <- data.frame(z = z_scores)

ggplot(df_z, aes(x = z)) +
  geom_histogram(bins = 30, fill = "gray60", color = "black") +
  geom_vline(xintercept = z_posebna, linewidth = 1.2, linetype = "dashed") +
  annotate("text", x = z_posebna + 0.3, y = 45,
           label = paste0("Osoba X\nz = ", round(z_posebna, 2)),
           hjust = 0, size = 3.5) +
  labs(
    title = "Distribucija z-vrijednosti (N = 500)",
    subtitle = "Z-vrijednosti imaju prosjek 0 i SD = 1",
    x = "Z-vrijednost",
```

```
  y = "Frekvencija"
)
```

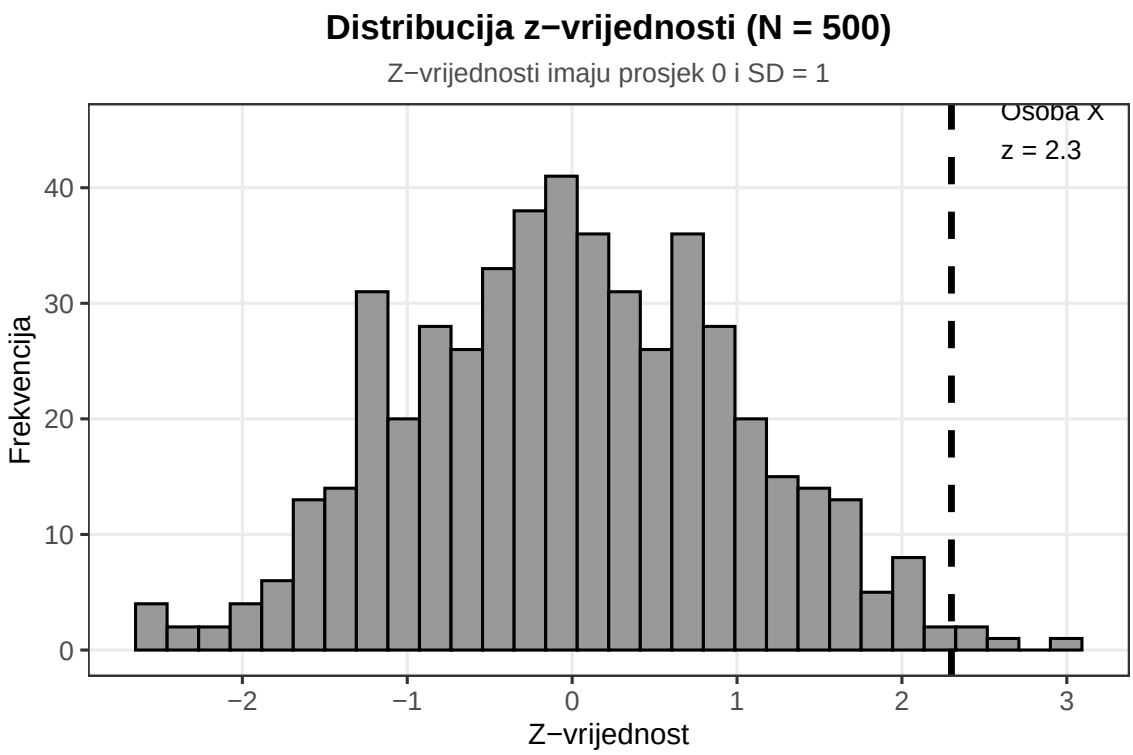


Figure 6: Distribucija z-vrijednosti rezultata upitnika o dijeljenju dezinformacija (N = 500). Isprekidana linija označava z-vrijednost od 2.33 koja odgovara osobi s rezultatom 145. Vidljivo je da se gotovo svi rezultati nalaze između -3 i +3, a osoba s z = 2.33 zaista se nalazi u samom repu distribucije.

Z-vrijednosti imaju dva ključna i važna svojstva. Prvo, distribucija z-vrijednosti uvijek ima prosjek 0 i standardnu devijaciju 1, bez obzira kakva je bila originalna distribucija ili originalni oblik podataka prije standardizacije. Kada se od svake vrijednosti oduzme prosjek, distribucija se centrira oko nule; kada se podijeli sa standardnom devijacijom, distribucija se skalira tako da standardna devijacija postane točno 1. Drugo, z-vrijednosti omogućuju smislenu i direktnu usporedbu između varijabli ili mjerenja koja su mjerena na potpuno različitim skalama ili s različitim mjernim jedinicama. Broj dnevnih objava na društvenim mrežama, koji se tipično varira od 0 do 20, ne može se direktno ili smisleno usporediti s vremenom provedenim na platformi, koje se varira od 0 do 300 minuta, jer imaju različite mjerne jedinice. Međutim, ako se obje varijable standardiziraju u z-vrijednosti, moguće je usporediti relativne pozicije ili "neuobičajenost". Osoba s z-vrijednošću od 1.5 za broj objava i 0.8 za vrijeme provedeno je "neuobičajenija" u broju objava (daleko iznad prosjeka), dok je osoba sa z-vrijednostima 0.5 i 2.0 "neuobičajenija" u vremenu provedenom. Ova usporedba bila bi nemoguća ili besmislena sa sirovim, nestandardiziranim rezultatima.

U komunikološkom istraživanju, standardizirani rezultati ili z-vrijednosti koriste se za nekoliko praktičnih namjena. Koriste se za identifikaciju outliera (članak s z-vrijednosti od 4.5 za broj komentara zaslužuje posebnu pažnju budući da je ekstremno neuobičajan), za kreiranje kompozitnih indeksa ili složenih mjerila (kombiniranje broja lajkova, komentara i dijeljenja u uravnoteženi "indeks angažmana", pri čemu bi bez standardizacije lajkovi dominirali indeks samo zato što su na većoj skali ili broju), te u naprednim statističkim analizama poput višestruke regresije, o kojoj je riječ u poglavlju 10.

#### 0.1.3.2 Pearsonov koeficijent korelacije

**Pearsonov koeficijent korelacije** ($r$) predstavlja matematičku mjeru ili kvantitativnu vrijednost koja kvantificira jačinu i smjer linearnog odnosa između dviju varijabli. Prije nego što se uvede formalna matematička mjera, važno je razumjeti kako se odnosi između varijabli vizualno procjenjuju i detektiraju. **Dijagram raspršenja** (engl. *scatterplot*) je osnovni i nezamjenjiv alat za tu svrhu – svaka opservacija ili pojedinačni slučaj reprezentiran je kao točka u dvodimenzionalnom prostoru gdje x-koordinata odgovara vrijednosti prve varijable, a y-koordinata vrijednosti druge varijable. Ako točke formiraju obrazac ili trend koji ide odozdo lijevo prema gore desno, to sugerira **pozitivan odnos**: porast jedne varijable tendira biti praćen porastom druge. Ako točke idu od gore lijevo prema dolje desno, to ukazuje na **negativan odnos**: porast jedne varijable je povezan s padom druge. Ako su točke nasumično raspršene bez jasnog obrasca ili trenda, to sugerira da ne postoji sistematičan linearan odnos između varijabli.

**Koeficijent korelacije** varira između -1 i +1, pri čemu $r = +1$ indicira ili označava savršenu pozitivnu korelaciju (sve točke leže točno na rastućoj pravoj liniji), $r = -1$ indicira savršenu negativnu korelaciju (sve točke leže točno na padajućoj pravoj liniji), a $r = 0$ indicira nikakvu linearnu korelaciju. Da bi se razumjelo kako se korelacija izračunava i što je matematički temelj, potrebno je uvesti koncept **kovarijance**, tj. mjere koja kvantificira koliko dvije varijable variraju ili kovariraju zajedno:

$$\mathrm{Cov}(X, Y) = \frac{1}{N-1} \sum_{i=1}^{N} (X_i - \bar{X})(Y_i - \bar{Y})$$

Ova formula matematički govori sljedeće: za svaku opservaciju gleda se koliko $X$ odstupa od svog prosjeka i koliko $Y$ odstupa od svog prosjeka, a zatim se ta dva odstupanja množe zajedno. Ako obje varijable tendiraju biti iznad prosjeka u isto vrijeme (ili obje ispod prosjeka), umnošci su pozitivni, što rezultira pozitivnom kovarijancom koja indicira pozitivan odnos. Ako jedna tendira biti iznad prosjeka kada je druga ispod prosjeka, umnošci su negativni, što indicira negativnu kovarijancu i negativan odnos.

Međutim, kovarijanca ima važan praktičan problem: njezina veličina ovisi o jedinicama mjerenja ili skali varijabli. Ako se mjeri duljina članka u riječima i broj komentara kao broj, kovarijanca je u "riječi × komentari", što nema nikakvo razumljivo ili interpretabilno značenje jer su jedinice besmislene. **Pearsonov koeficijent korelacije** elegantno rješava ovaj problem standardizacijom ili normalizacijom, tj. dijeli kovarijancu s umnoškom standardnih devijacija obiju varijabli:

$$r_{XY} = \frac{\mathrm{Cov}(X, Y)}{s_X \cdot s_Y}$$

Dijeleći kovarijancu s umnoškom standardnih devijacija, dobiva se bezdimenzionalna mjera koja uvijek pada između -1 i +1. Postoji i elegantna alternativna formula koja eksplicitno povezuje korelaciju sa z-vrijednostima: $r_{XY} = \frac{1}{N-1} \sum_{i=1}^{N} z_{X_i} \cdot z_{Y_i}$, što pokazuje da je korelacija zapravo prosječan umnožak standardiziranih rezultata ili z-vrijednosti. U statističkom programu R se korelacija izračunava funkcijom `cor()`, a kovarijanca funkcijom `cov()`.

```
set.seed(789)
n <- 80

# Pozitivna korelacija
x1 <- rnorm(n, 50, 10)
y1 <- 0.85 * x1 + rnorm(n, 0, 5)

# Negativna korelacija
x2 <- rnorm(n, 50, 10)
y2 <- -0.65 * x2 + 80 + rnorm(n, 0, 7)

# Bez korelacije
x3 <- rnorm(n, 50, 10)
y3 <- rnorm(n, 50, 10)

df_cor <- data.frame(
  x = c(x1, x2, x3),
  y = c(y1, y2, y3),
  tip = factor(rep(c(
    paste0("Pozitivna (r = ", round(cor(x1, y1), 2), ")"),
    paste0("Negativna (r = ", round(cor(x2, y2), 2), ")"),
    paste0("Bez korelacije (r = ", round(cor(x3, y3), 2), ")")
  ), each = n), levels = c(
    paste0("Pozitivna (r = ", round(cor(x1, y1), 2), ")"),
    paste0("Negativna (r = ", round(cor(x2, y2), 2), ")"),
    paste0("Bez korelacije (r = ", round(cor(x3, y3), 2), ")")
  ))
)

ggplot(df_cor, aes(x = x, y = y)) +
  geom_point(alpha = 0.7, size = 1.5) +
  geom_smooth(method = "lm", se = FALSE, color = "black", linewidth = 0.8) +
  facet_wrap(~tip, scales = "free") +
  labs(
    title = "Primjeri različitih korelacija",
    x = "Varijabla X",
```

```
    y = "Varijabla Y"
  ) +
  theme(strip.text = element_text(face = "bold"))
```

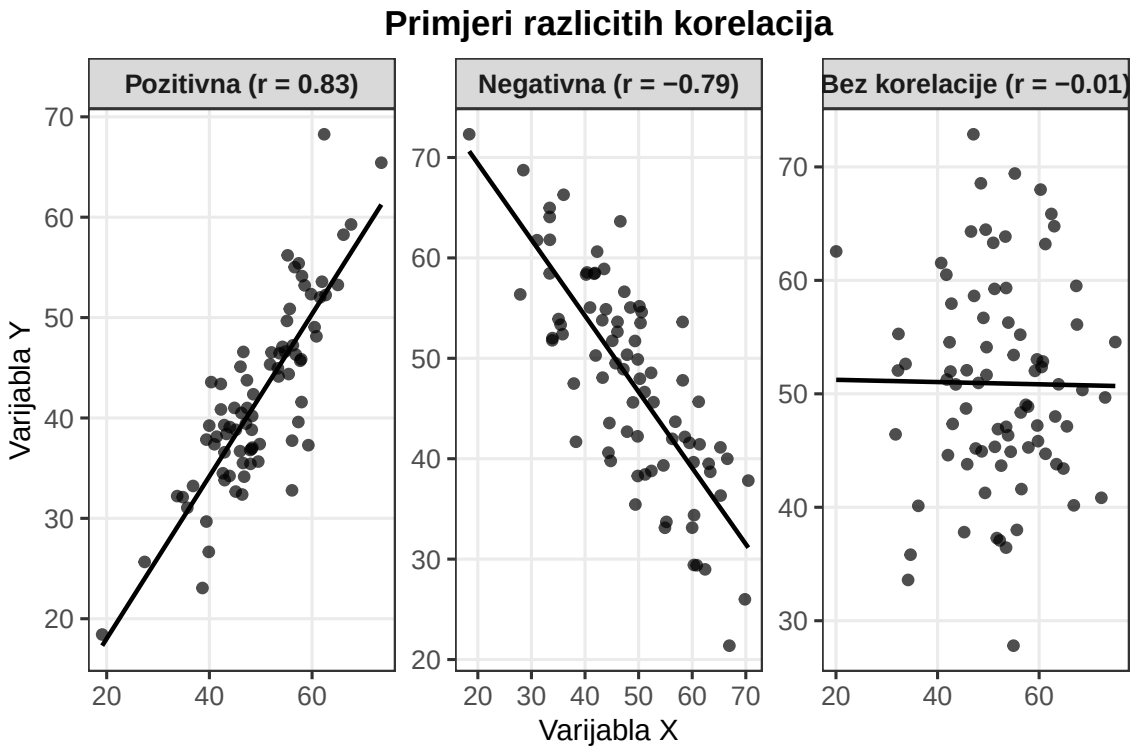


Figure 7: Primjeri različitih korelacija. Lijevi panel pokazuje jaku pozitivnu korelaciju, srednji panel umjerenu negativnu, a desni panel pokazuje podatke bez linearne korelacije. Pravci regresije naznačuju smjer odnosa.

Za interpretaciju koeficijenta korelacije koriste se opće smjernice ili praktičan referentni okvir koji je prikazvan u sljedećoj tablici.

Table 4: Smjernice za interpretaciju korelacije prema apsolutnoj vrijednosti koeficijenta. Valja naglasiti da su ove granice okvirne i da konkretna interpretacija uvijek ovisi o kontekstu istraživanja. U istraživanju masovne komunikacije, korelacija od $r = 0.35$ između izloženosti vijestima i političkog znanja mogla bi biti supstantivno značajna, dok u istraživanju pouzdanosti mjernog instrumenta korelacija ispod 0.80 može ukazivati na ozbiljan problem.

| Apsolutna vrijednost $\|r\|$ | Interpretacija |
|---|---|
| 0.00 – 0.19 | Vrlo slaba ili zanemariva |
| 0.20 – 0.39 | Slaba |
| 0.40 – 0.59 | Umjerena |

| Apsolutna vrijednost $\|r\|$ | Interpretacija |
|---|---|
| 0.60 – 0.79 | Jaka |
| 0.80 – 1.00 | Vrlo jaka |

**Ograničenja Pearsonove korelacije** moraju se čvrsto razumjeti za pravilnu i nepristranu interpretaciju rezultata. Prva i najvažnija stvarnost je da korelacija mjeri samo **linearne** odnose, pa ako je odnos između varijabli krivolinijski ili nelinearan (primjerice obrnuta U krivulja ili kvadratna funkcija), korelacija može biti blizu nule čak i kada postoji jaka sistematična veza između varijabli. Nadalje, korelacija je značajno osjetljiva na outliere budući da jedna ekstremna ili neuobičajena točka može značajno utjecati i "povući" vrijednost koeficijenta. Konačno, i to je možda najvažnije ograničenje koje se često zaboravlja: **korelacija ne implicira ili ne dokazuje uzročnost**. Ako se pronađe da je vrijeme provedeno na Facebooku korelirano s političkom polarizacijom ili ekstremizmom, to kategorički ne znači nužno da Facebook uzrokuje polarizaciju. Moguće je da Facebook uzrokuje polarizaciju, da polarizacija uzrokuje veću upotrebu Facebooka, da treća, promatrana ili nepromatrana varijabla uzrokuje oboje simultano, ili da je pronađena povezanost slučajna ili artefakt metodologije. Za temeljna zaključke o uzročnosti ili kauzalnosti potrebni su eksperimentalni dizajni, randomizovane kontrolirane pokuse ili napredne kauzalne metode, o čemu se detaljnije govori u poglavlju 3 (Nacrt istraživanja) i poglavlju 10 (Statistički testovi u praksi).

Razmotrimo konkretan praktičan primjer iz komunikološkog istraživanja. Analitičar istražuje nekoliko dimenzija ili varijabli vezanih uz portal Večernji.hr i njihove međuodnose. Analizira se dnevni broj objavljenih članaka ($M = 25.4$, $SD = 4.2$), prosječno vrijeme čitanja po člankuu ($M = 142$ sekundi, $SD = 28$) i ukupan dnevni broj komentara ($M = 450$, $SD = 120$). Korelacijska matrica ili tablica koja prikazuje sve međuodnose je sljedeća.

Table 5: Korelacijska matrica za podatke portala Večernji.hr. Najsnažniji odnosjest umjereno jaka pozitivna korelacija ($r = 0.58$) između vremena čitanja i broja komentara, što sugerira da angažiraniji sadržaj koji zadržava čitatelje rezultira većom interakcijom. Slaba negativna korelacija ($r = -0.32$) između broja članaka i vremena čitanja mogla bi značiti da veća količina objavljenog sadržaja rezultira površnijim čitanjem.

| | Broj članaka | Vrijeme čitanja | Ukupni komentari |
|---|---|---|---|
| **Broj članaka** | 1.00 | -0.32 | 0.15 |
| **Vrijeme čitanja** | -0.32 | 1.00 | 0.58 |
| **Ukupni komentari** | 0.15 | 0.58 | 1.00 |

Ovakva korelacijska matrica u R-u se jednostavno izračunava pozivom funkcije `cor(podaci)`, gdje je `podaci` data frame s numeričkim stupcima. Analiza pokazuje da je angažiraniji sadržaj koji zadržava čitatelje dulje i bolje rezultira većom interakcijom ili brojem komentara. Ovaj nalaz može imati praktične implikacije za uredničke odluke o vrsti sadržaja, dužini članaka ili strategiji objavljivanja, ali valja biti oprezan s bilo kakvom kauzalnom interpretacijom jer

korelacijska analiza sama po sebi ne može dokazati je li duže vrijeme čitanja uzrok većega angažmana ili obrnuto.

Nakon što je utvrđeno kako se numerički opisuju i uspoređuju varijable kroz sve te mjere, sljedeći korak jest vizualno prikazati podatke. Vizualizacija podataka ne samo da logički nadopunjuje numeričke statistike, već često može otkriti obrasce, trendove i anomalije koji bi iz samih brojki ostali skriveni ili nevidljivi.

### 0.1.4 Vizualizacija podataka

Brojke ili numerički podaci sami po sebi rijetko govore dovoljno jasnu ili intuitivnu priču, posebno laicima. Prosječna gledanost od 285.000 gledatelja sa standardnom devijacijom od 42.000 pruža određeni kvantitativni uvid, ali taj uvid postaje daleko moćniji, informativniji i lakše razumljiv kada se vizualizira ili grafički prikaze. Grafički prikazi ili vizualizacije mogu otkriti obrasce koji numeričkim statistikama često ostaju skriveni, poput bimodalnih ili kompleksnih distribucija, ekstremnih vrijednosti ili outliera, nelinearnih odnosu ili latentnih subgrupa u podacima. Edward Tufte, utjecajni teoretičar vizualizacije podataka, sažeo je ovu ideju jednostavno ali duboko: cilj svake vizualizacije jest, prije svega, pokazati podatke što je jasnije moguće (Tufte, 2001). U nastavku se obrađuju četiri temeljne vrste grafova koje pokrivaju većinu praktičnih potreba u istraživanju masovne komunikacije, uz prikaz R koda za svaki od njih.

#### 0.1.4.1 Histogram

**Histogram** predstavlja jednu od osnovnih i najvažnijih vizualizacijskih alatki koja prikazuje distribuciju ili raspodjelu vrijednosti pojedinačne numeričke varijable. Histogram dijeli raspon vrijednosti na nekoliko intervala (tzv. *binove*) i prikazuje koliko opservacija pada u svaki interval. Na x-osi nalaze se intervali vrijednosti, a na y-osi frekvencije ili broj opservacija. Za istraživača masovne komunikacije, histogram je nezamjenjiv alat za razumijevanje kako su podaci distribuirani, posebno prije nego što se pristupi bilo kakvim naprednim analizama.

Zamislimo da se analizira trajanje 200 video clipova na YouTube kanalu RTL-a. Histogram odmah otkriva jesu li većina videa sličnog trajanja ili variraju široko, postoje li jasne modalne vrijednosti ili "vrhovi" u distribuciji (primjerice klaster oko 2 minute za kratke vijesti i drugi oko 10 minuta za dugačke reportaže), postoje li outlieri koji zahtijevaju posebnu pažnju te je li distribucija simetrična ili asimetrična ili iskrivljena. Histogram koji pokazuje dva jasna vrha ili "grba", tj. bimodalnu distribuciju, može otkriti da portal proizvodi dvije distinktivne vrste sadržaja sa različitim trajanjem, što je dragocjen uvid koji bi se izgubio kada bi se razmatrala samo statistika kao prosjek i standardna devijacija.

```r
set.seed(111)
# Simulacija trajanja videa (u sekundama)
kratke_vijesti <- rnorm(120, mean = 120, sd = 25)
duge_reportaze <- rnorm(60, mean = 600, sd = 90)
srednji <- rnorm(20, mean = 300, sd = 40)
```

```r
trajanje_videa <- c(kratke_vijesti, duge_reportaze, srednji)
df_trajanje <- data.frame(trajanje = trajanje_videa / 60)  # pretvorba u minute

ggplot(df_trajanje, aes(x = trajanje)) +
  geom_histogram(bins = 25, fill = "gray60", color = "black") +
  geom_vline(xintercept = mean(df_trajanje$trajanje), linetype = "dashed", linewidth = 0.8
  annotate("text", x = 5, y = 32,
           label = "Bimodalna distribucija:\n1. Kratke vijesti (~2 min)\n2. Duge reportaže
           hjust = 0, size = 3) +
  labs(
    title = "Trajanje videa na YouTube kanalu RTL-a (N = 200)",
    subtitle = paste("Prosjek =", round(mean(df_trajanje$trajanje), 1),
                     "min (isprekidana linija)"),
    x = "Trajanje (minute)",
    y = "Frekvencija"
  )
```

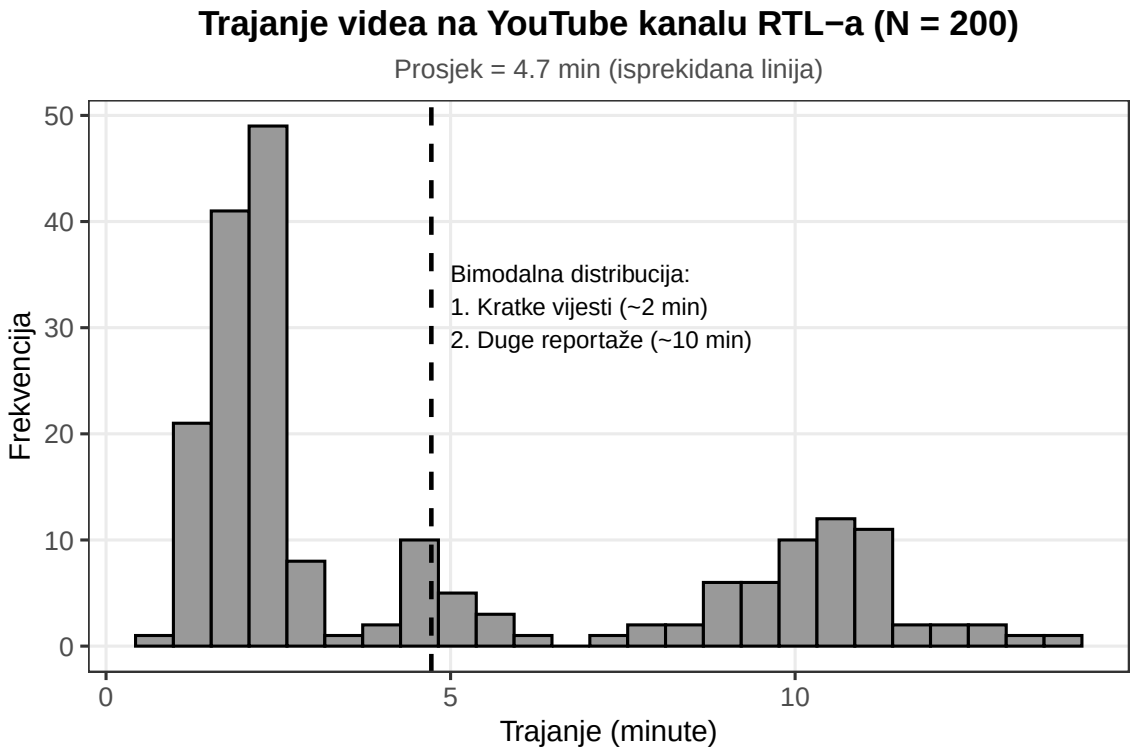


Figure 8: Bimodalna distribucija trajanja YouTube videa na kanalu RTL-a. Jasno su vidljiva dva vrha: jedan oko 2 minute (kratke vijesti) i drugi oko 10 minuta (duže reportaže). Isprekidana linija označava aritmetičku sredinu koja u ovom slučaju pada između dvaju modova i ne reprezentira niti jednu od dviju grupa. Ovaj primjer ilustrira zašto je vizualizacija nužna prije izvještavanja numeričkih statistika.

U statističkom programu R se histogram kreira pomoću `geom_histogram()` funkcije iz paketa ggplot2. Ključ ili kritični čimbenik dobroga histograma leži u izboru broja intervala ili binova. Premalo intervala stvara grub ili hrbar prikaz koji skriva važne detalje distribucije, dok previše intervala stvara isprekidan prikaz gdje svaki bin sadrži samo nekoliko opservacija, čime se gubi ukupan oblik. Kao opće empirijsko pravilo, za uzorke od 50 do 100 opservacija obično je prikladno 7 do 10 intervala, dok veći uzorci mogu koristiti više intervala bez gubitka kvalitete. U ggplot2, broj intervala ili binova kontrolira se argumentom `bins` unutar `geom_histogram()`.

#### 0.1.4.2 Box plot

**Box plot** ili **dijagram pravokutnika** elegantno sažima distribuciju pojedinačne numeričke varijable kroz pet ključnih deskriptivnih statistika: minimum, prvi kvartil (Q1), medijan, treći kvartil (Q3) i maksimum. U vizualnom prikazu, pravokutnik obuhvaća međukvartilni raspon (od Q1 do Q3) s linijom označenom na medijanu, dok se "brkovi" ili linije protežu prema najnižim i najvišim vrijednostima koje nisu klasificirane kao outlieri. Točke ili kružići izvan brkova, tj. vrijednosti udaljene više od 1.5×IQR od rubova pravokutnika, označavaju outliere ili ekstremne vrijednosti.

Box plot je idealan i posebno vrijedan za usporedbe između grupa ili kategorija. Usporedba gledanosti emisija na HRT-u, Nova TV-u i RTL-u pomoću triju paralelnih box plotova odmah otkriva ne samo razlike u medijanima (koja televizija ima veću "tipičnu" gledanost), već i razlike u varijabilnosti (koja televizija pokazuje konzistentniju gledanost) i prisutnost eventualnih ekstremnih vrijednosti ili outliera koji mogu zahtijevati posebnu pažnju.

```r
set.seed(222)
# Simulacija gledanosti za tri TV kuće (u tisućama)
gledanost_tv <- data.frame(
  gledanost = c(
    rnorm(50, mean = 250, sd = 35),
    rnorm(50, mean = 310, sd = 50),
    rnorm(50, mean = 280, sd = 42)
  ),
  tv_kuca = rep(c("HRT", "Nova TV", "RTL"), each = 50)
)

# Dodavanje outliera
gledanost_tv$gledanost[c(10, 60, 110)] <- c(380, 480, 420)

ggplot(gledanost_tv, aes(x = tv_kuca, y = gledanost)) +
  geom_boxplot(fill = "gray80", color = "black",
               outlier.shape = 1, outlier.size = 2) +
  stat_summary(fun = mean, geom = "point", shape = 18, size = 3) +
  labs(
    title = "Gledanost večernjih vijesti po TV kućama",
```

```
    subtitle = "Romb označava prosjek | Kružići su outlieri",
    x = "TV kuća",
    y = "Gledanost (tisuće)"
  )
```

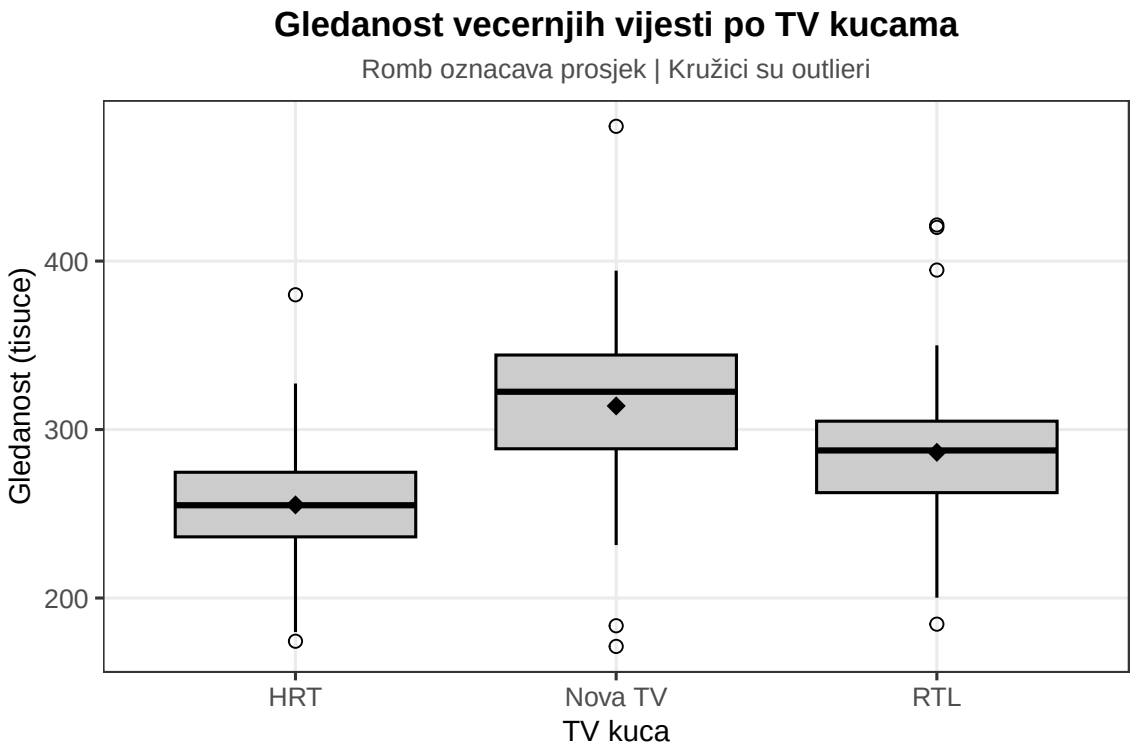


Figure 9: Usporedba gledanosti između televizijskih kuća pomoću box plotova. Romb označava aritmetičku sredinu, a kružići outliere. Vidljivo je da Nova TV ima najvišu medijansku gledanost ali i najveću varijabilnost, dok HRT pokazuje najkonzistentniju gledanost s najužim pravokutnikom.

U statističkom programu R se box plot kreira pomoću `geom_boxplot()` iz paketa ggplot2. Box plot je posebno vrijedan kao vizualizacijski alat jer je robustan na outliere, čineći ih vidljivima kao zasebne točke bez iskrivljavanja glavnog prikaza distribucije i bez iskrivljavanja našega razumijevanja tipičnih vrijednosti. Također omogućuje brzu vizualnu procjenu asimetrije ili skewness: ako medijan nije u sredini pravokutnika, distribucija je asimetrična. Medijan bliži donjem rubu sugerira pozitivno asimetričnu distribuciju (rep prema višim vrijednostima ili desno), dok medijan bliži gornjem rubu sugerira negativno asimetričnu distribuciju (rep prema nižim vrijednostima ili lijevo).

#### 0.1.4.3 Dijagram raspršenja

**Dijagram raspršenja** (engl. *scatterplot*) prikazuje odnos između dviju numeričkih varijabli tako što svaku opservaciju ili pojedinačni slučaj reprezentira kao točku u dvodimenzionalnom prostoru ili grafu. Na x-osi je jedna varijabla, na y-osi druga, a svaka točka predstavlja jednu opservaciju. Dijagram raspršenja je fundamentalan alat za istraživanje korelacija i odnosa jer vizualno otkriva smjer odnosa, jačinu odnosa, linearnost ili nelinearnost odnosa te prisutnost outliera koji mogu utjecati na kauzalne zaključke.

```r
set.seed(333)
n <- 100
# Simulacija podataka: duljina članka i broj komentara
duljina_clanka <- rnorm(n, mean = 800, sd = 250)
broj_komentara <- 5 + 0.06 * duljina_clanka + rnorm(n, mean = 0, sd = 15)

# Dodavanje outliera (viralni članci)
duljina_clanka <- c(duljina_clanka, 600, 750)
broj_komentara <- c(broj_komentara, 180, 220)

df_index <- data.frame(
  duljina = duljina_clanka,
  komentari = broj_komentara
)

r_val <- cor(df_index$duljina, df_index$komentari)

ggplot(df_index, aes(x = duljina, y = komentari)) +
  geom_point(alpha = 0.7, size = 2) +
  geom_smooth(method = "lm", se = TRUE, color = "black", fill = "gray80") +
  annotate("text", x = 400, y = 200,
           label = paste("r =", round(r_val, 2)),
           size = 4, fontface = "bold") +
  labs(
    title = "Duljina članka vs. Broj komentara (Index.hr)",
    subtitle = "Linija = linearna regresija | Sivo područje = 95% CI",
    x = "Duljina članka (riječi)",
    y = "Broj komentara"
  )
```

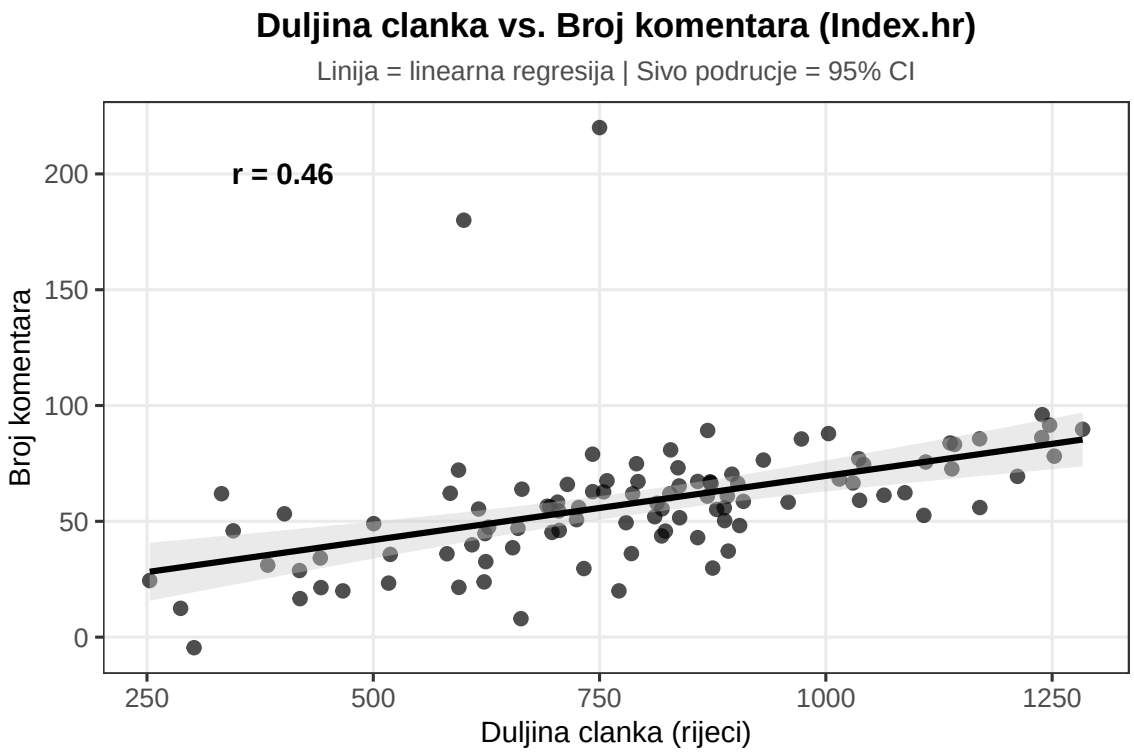


Figure 10: Odnos između duljine članka i broja komentara na portalu Index.hr. Linija linearne regresije i sivo područje (95%-tni interval pouzdanosti) sugeriraju slab pozitivan trend, ali dvije točke s izuzetno visokim brojem komentara jasno su vidljive kao outlieri. Bez dijagrama raspršenja, sama korelacija ne bi razotkrila ove ekstremne slučajeve.

U statističkom programu R se dijagram raspršenja kreira pomoću `geom_point()` i `geom_smooth()` iz paketa ggplot2. Korelacija nikad ne bi trebala biti izvještana niti interpretirana bez vizualnog pregleda putem dijagrama raspršenja. **Anscombeov kvartet** je poznat i instruktivan primjer koji demonstrira da četiri potpuno različita skupa podataka mogu imati identične korelacijske koeficijente, identične prosjeke i identične standardne devijacije, a ipak pokazivati fundamentalno različite obrasce kada se vizualiziraju (Anscombe, 1973). Jedan skup može pokazivati linearni odnos, drugi krivolinijski, treći može imati jedan utjecajan outlier, a četvrti može imati potpuno drugačiju strukturu. Samo dijagram raspršenja otkriva ove kritične i značajne razlike.

#### 0.1.4.4 Stupčasti grafikon

**Stupčasti grafikon** (engl. *bar plot*) prikazuje frekvencije ili prosjeke za kategorijske varijable. Za analizu sadržaja medija, stupčasti grafikoni su prirodan i intuitivan izbor za prikaz distribucija tema, žanrova ili drugih nominalnih varijabli.

```r
# Podatci o distribuciji tema u vijestima HRT-a
teme_hrt <- data.frame(
  tema = c("Politika", "Gospodarstvo", "Kriminal", "Međunarodno",
           "Zdravstvo", "Sport", "Kultura", "Ostalo"),
  frekvencija = c(45, 28, 22, 20, 18, 15, 12, 10)
)

# Sortiranje prema frekvenciji
teme_hrt <- teme_hrt[order(-teme_hrt$frekvencija), ]
teme_hrt$tema <- factor(teme_hrt$tema, levels = teme_hrt$tema)

ggplot(teme_hrt, aes(x = tema, y = frekvencija)) +
  geom_col(fill = "gray50", color = "black", width = 0.7) +
  geom_text(aes(label = frekvencija), vjust = -0.5, size = 3.5) +
  labs(
    title = "Dominantne teme u HRT Dnevniku (170 izvještaja)",
    x = "",
    y = "Broj izvještaja"
  ) +
  ylim(0, 52) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

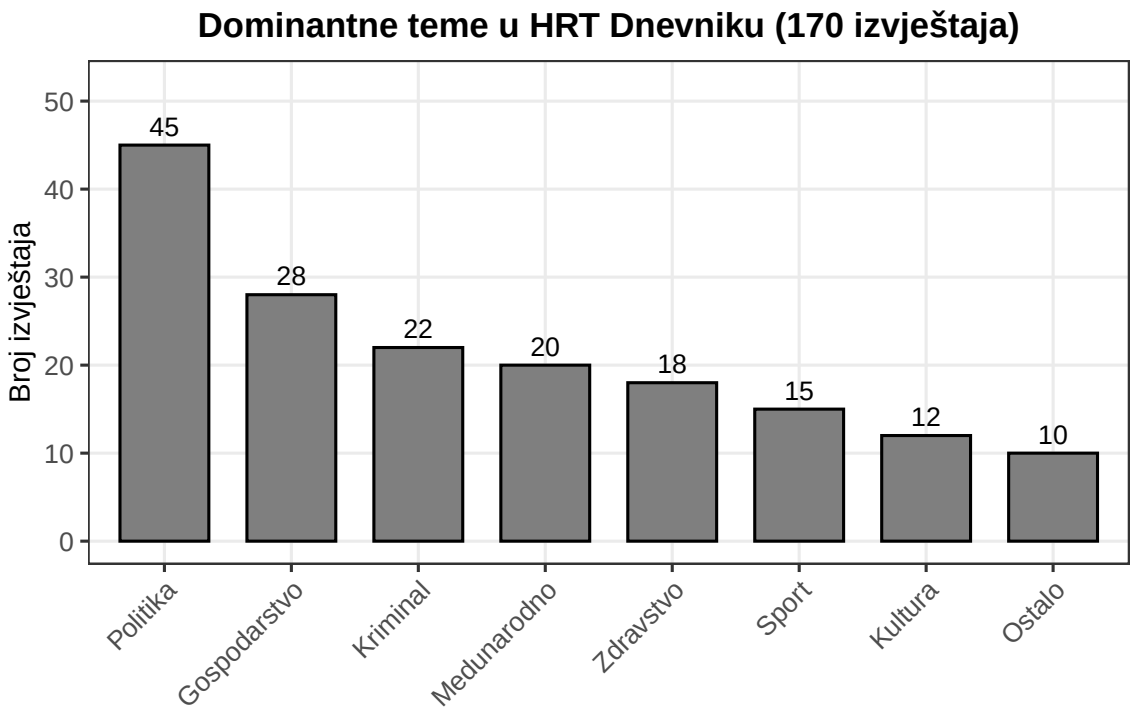


Figure 11: Distribucija tema u glavnim vijestima HRT-a. Stupci su sortirani prema frekvenciji, što olakšava vizualnu usporedbu. Politika je dominantna tema s 45 izvještaja, dok su kulturni sadržaji zastupljeni s tek 12 izvještaja, što ukazuje na izrazitu tematsku neravnotežu u medijskom prostoru.

U statističkom programu R se stupčasti grafikon kreira pomoću `geom_col()` ili `geom_bar()` iz paketa ggplot2. Osim jednostavnih frekvencija, stupčasti grafikoni mogu prikazivati grupiranu usporedbu (primjerice distribuciju tema na HRT-u, Nova TV-u i RTL-u usporedno kao grupirane stupce) ili usporedbu prosjeka između grupa. Pri kreiranju stupčastih grafikona za nominalne varijable bez inherentnog redoslijeda, izrazito je korisno sortirati stupce od najviše do najniže vrijednosti jer to olakšava vizualne usporedbe i čini graf informativnijim te lakšim za interpretaciju.

#### 0.1.4.5 Principi učinkovite vizualizacije

Neovisno o vrsti grafa ili vizualizacije koju koristimo, nekoliko temeljnih načela osigurava da vizualizacije komuniciraju jasno, točno i bez iskrivljavanja. **Samoobjasnljivost** znači da graf mora biti razumljiv i interpretabilan bez nužnosti čitanja okolnog teksta ili detaljnog objašnjenja, što zahtijeva jasne, informativne naslove, oznake osi s eksplicitno navedenim mjernim jedinicama i legendu kada graf prikazuje više grupa. **Minimalna dekoracija** podrazumijeva aktivno izbjegavanje 3D efekata, nepotrebnih i odvlačućih boja, grafičkih ukrasa ili dekorativnih elemenata koji ometaju ili otežavaju čitanje podataka – Tufte (2001) je

ovaj princip nazvao maksimiziranjem omjera podataka prema "tinti" ili grafičkim elementima. **Pažljiv odabir skala** osigurava da graf ne preuveličava niti umanjuje razlike; y-os stupčastih grafikona trebala bi uvijek počinjati od nule kako bi se izbjegle vizualne distorzije ili optičke iluzije. Konačno, **jasno razlikovanje grupa** zahtijeva jasne i razlikovne oznake i legendu kada se prikazuje više grupa ili varijabli kako bi čitatelja vodilo kroz podatke.

Sljedeća tablica sažima koji je tip vizualizacije najprikladniji za koji tip podataka i istraživačkog pitanja.

Table 6: Smjernice za odabir tipa vizualizacije prema vrsti podataka i istraživačkom pitanju. Ova tablica služi kao brza referenca za studente pri donošenju odluke o tome koji graf koristiti u konkretnoj situaciji.

| Tip vizualizacije | Vrsta podataka | Istraživačko pitanje | Funkcija u R-u (ggplot2) |
|---|---|---|---|
| Histogram | Jedna numerička varijabla | Kakav je oblik distribucije? | `geom_histogram()` |
| Box plot | Numerička po grupama | Kako se distribucije razlikuju? | `geom_boxplot()` |
| Dijagram raspršenja | Dvije numeričke varijable | Postoji li odnos između varijabli? | `geom_point()` |
| Stupčasti grafikon | Kategorijska varijabla | Koje su kategorije najčešće? | `geom_col()` |

### 0.1.5 Cjeloviti primjer: od sirovih podataka do deskriptivnog izvještaja

Nakon pregleda pojedinačnih komponenti deskriptivne analize – mjera centralne tendencije, mjera disperzije, standardizacije, korelacije i vizualizacije – korisno je pokazati i demonstrirati kako se svi ovi elementi koriste zajedno u jednom cjelovitom, integralnom istraživačkom procesu. Sljedeći primjer demonstrira kompletni tijek deskriptivne analize na simuliranim podacima o angažmanu čitatelja na hrvatskom informativnom portalu.

Zamislimo da je analitičar prikupio podatke o 150 članaka objavljenih na portalu Večernji.hr tijekom jednog mjeseca. Za svaki članak zabilježena je tematska kategorija, duljina članka u riječima, broj komentara ili interakcija te prosječno vrijeme čitanja izraženo u sekundama.

```r
set.seed(2024)

# Simulacija podataka o 150 članaka
n_clanaka <- 150
teme <- sample(c("Politika", "Gospodarstvo", "Sport", "Kultura", "Crna kronika"),
               n_clanaka, replace = TRUE, prob = c(0.30, 0.20, 0.20, 0.15, 0.15))

# Duljina članka ovisi o temi
duljina <- ifelse(teme == "Politika", rnorm(n_clanaka, 950, 200),
```

```r
            ifelse(teme == "Gospodarstvo", rnorm(n_clanaka, 800, 180),
            ifelse(teme == "Sport", rnorm(n_clanaka, 500, 120),
            ifelse(teme == "Kultura", rnorm(n_clanaka, 1100, 250),
                   rnorm(n_clanaka, 650, 150)))))
duljina <- pmax(duljina, 100)  # minimalna duljina

# Broj komentara
komentari_sim <- 2 + 0.03 * duljina + rnorm(n_clanaka, 0, 10)
komentari_sim <- pmax(round(komentari_sim), 0)

# Prosječno vrijeme čitanja (sekunde)
vrijeme <- 30 + 0.12 * duljina + rnorm(n_clanaka, 0, 20)
vrijeme <- pmax(vrijeme, 15)

df_portal <- data.frame(
  tema = teme,
  duljina_rijeci = round(duljina),
  broj_komentara = komentari_sim,
  vrijeme_citanja = round(vrijeme)
)

# 1. KORAK: Pregled strukture podataka
cat("=== STRUKTURA PODATAKA ===\n")
```

```
=== STRUKTURA PODATAKA ===
```

```r
cat("Broj članaka:", nrow(df_portal), "\n")
```

```
Broj članaka: 150
```

```r
cat("Varijable:", paste(names(df_portal), collapse = ", "), "\n\n")
```

```
Varijable: tema, duljina_rijeci, broj_komentara, vrijeme_citanja
```

```r
# 2. KORAK: Deskriptivna statistika za numeričke varijable
cat("=== DESKRIPTIVNA STATISTIKA ===\n\n")
```

```
=== DESKRIPTIVNA STATISTIKA ===
```

```r
# Funkcija za izračun svih ključnih mjera
opisna_stat <- function(x, naziv) {
  cat(naziv, ":\n")
  cat("  M =", round(mean(x), 2),
      "| SD =", round(sd(x), 2),
      "| Mdn =", round(median(x), 2),
      "| IQR =", round(IQR(x), 2),
      "| Min =", min(x),
      "| Max =", max(x), "\n\n")
}

opisna_stat(df_portal$duljina_rijeci, "Duljina članka (riječi)")
```

```
Duljina članka (riječi) :
  M = 818.18 | SD = 284.93 | Mdn = 816 | IQR = 389.25 | Min = 253 | Max = 1607
```

```r
opisna_stat(df_portal$broj_komentara, "Broj komentara")
```

```
Broj komentara :
  M = 27.34 | SD = 13.38 | Mdn = 28 | IQR = 20.75 | Min = 0 | Max = 59
```

```r
opisna_stat(df_portal$vrijeme_citanja, "Vrijeme čitanja (sek)")
```

```
Vrijeme čitanja (sek) :
  M = 124.96 | SD = 39.08 | Mdn = 123 | IQR = 50.5 | Min = 24 | Max = 229
```

```r
# 3. KORAK: Distribucija kategorijske varijable (mod)
cat("=== DISTRIBUCIJA TEMA ===\n")
```

```
=== DISTRIBUCIJA TEMA ===
```

```r
tablica_tema <- sort(table(df_portal$tema), decreasing = TRUE)
print(tablica_tema)
```

```
    Politika Gospodarstvo        Sport Crna kronika      Kultura
          49           30           28           23           20
```

```r
cat("Mod:", names(tablica_tema)[1], "\n\n")
```

```
Mod: Politika
```

```r
# 4. KORAK: Korelacijska matrica
cat("=== KORELACIJSKA MATRICA ===\n")
```

```
=== KORELACIJSKA MATRICA ===
```

```r
korelacije <- cor(df_portal[, c("duljina_rijeci", "broj_komentara", "vrijeme_citanja")])
print(round(korelacije, 2))
```

```
               duljina_rijeci broj_komentara vrijeme_citanja
duljina_rijeci            1.00           0.66            0.87
broj_komentara            0.66           1.00            0.59
vrijeme_citanja           0.87           0.59            1.00
```

```r
library(patchwork)

# Histogram duljine članaka
p1 <- ggplot(df_portal, aes(x = duljina_rijeci)) +
  geom_histogram(bins = 20, fill = "gray60", color = "black") +
  labs(title = "Distribucija duljine članaka",
       x = "Duljina (riječi)", y = "Frekvencija")

# Box plot komentara po temama
p2 <- ggplot(df_portal, aes(x = reorder(tema, broj_komentara, FUN = median),
                            y = broj_komentara)) +
  geom_boxplot(fill = "gray80", color = "black") +
  labs(title = "Komentari po temama",
       x = "", y = "Broj komentara") +
  coord_flip()

# Dijagram raspršenja: duljina vs komentari
p3 <- ggplot(df_portal, aes(x = duljina_rijeci, y = broj_komentara)) +
  geom_point(alpha = 0.6, size = 1.5) +
  geom_smooth(method = "lm", se = TRUE, color = "black", fill = "gray80") +
  labs(title = paste("Duljina vs. komentari (r =",
                     round(cor(df_portal$duljina_rijeci, df_portal$broj_komentara), 2), ")
       x = "Duljina (riječi)", y = "Broj komentara")

# Stupčasti grafikon tema
tema_count <- as.data.frame(table(df_portal$tema))
names(tema_count) <- c("tema", "frekvencija")
tema_count <- tema_count[order(-tema_count$frekvencija), ]
tema_count$tema <- factor(tema_count$tema, levels = tema_count$tema)

p4 <- ggplot(tema_count, aes(x = tema, y = frekvencija)) +
```

```
  geom_col(fill = "gray50", color = "black") +
  geom_text(aes(label = frekvencija), vjust = -0.5, size = 3) +
  labs(title = "Distribucija tema",
       x = "", y = "Broj članaka") +
  ylim(0, max(tema_count$frekvencija) + 5) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

# Kombinacija svih grafova
(p1 + p2) / (p3 + p4)
```

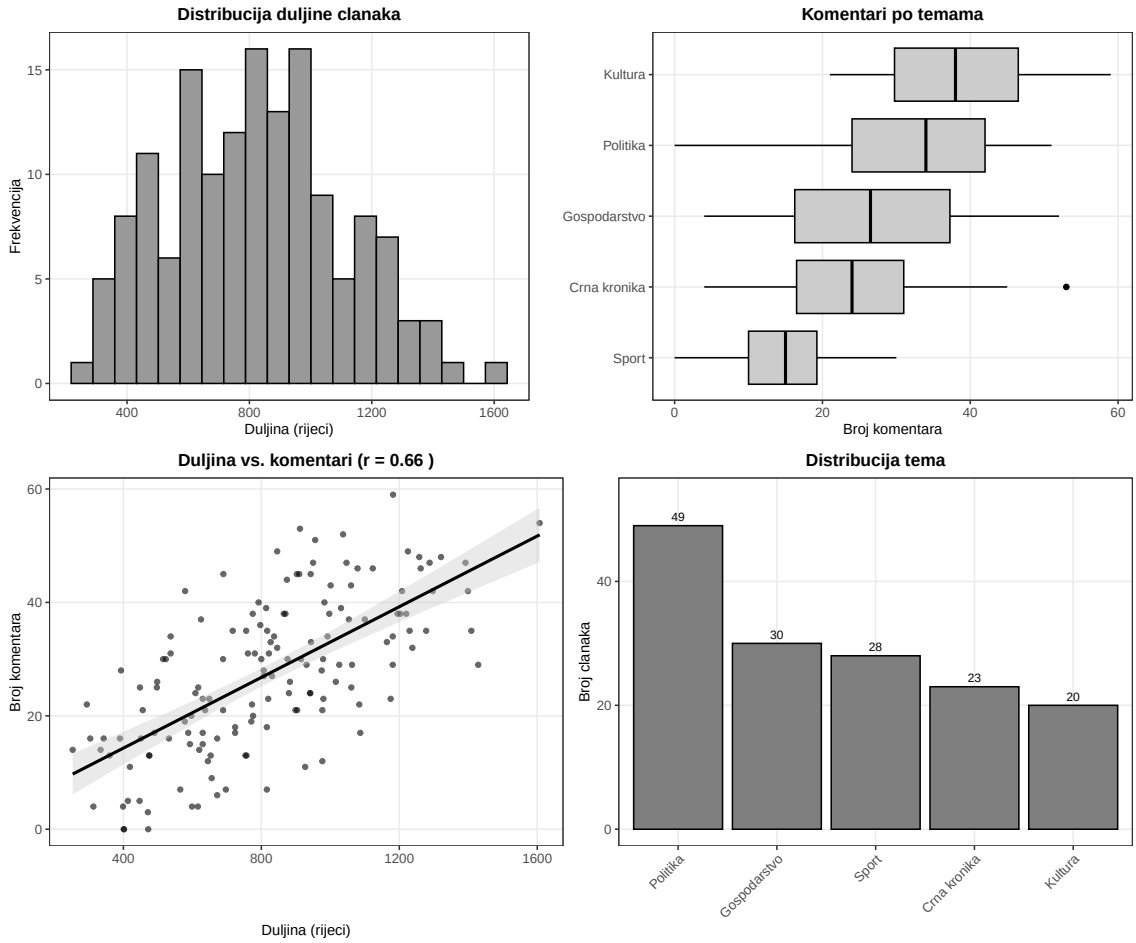


Figure 12: Vizualni pregled podataka portala Večernji.hr. Gornji lijevi panel prikazuje distribuciju duljine članaka (histogram), gornji desni usporedbu broja komentara po temama (box plot), donji lijevi odnos duljine članka i broja komentara (dijagram raspršenja), a donji desni distribuciju tema (stupčasti grafikon).

Ovaj kompleksni primjer ilustrira tipičan i reprezentativan tijek deskriptivne analize u praksi istraživanja masovne komunikacije. Analiza započinje sustavnim pregledom strukture

podataka, nastavlja se izračunom ključnih deskriptivnih mjera za svaku varijablu, te se zaključuje multidimenzionalnom vizualizacijom koja omogućuje brzo uočavanje obrazaca, trendova i potencijalnih problema. U statističkom programu R se čitav ovaj postupak može provesti u nekoliko desetaka linija koda, koristeći temeljne funkcije `mean()`, `sd()`, `median()`, `IQR()`, `cor()` i `table()` za numeričke izračune te paket ggplot2 za sve vizualizacije.

---

### 0.1.6 Sažetak poglavlja

**Deskriptivna statistika** pruža temeljne alate za sažimanje i opisivanje kvantitativnih podataka prikupljenih u istraživanju masovne komunikacije. Ovladavanje ovim tehnikama nužan je preduvjet za kompetentnu analizu i interpretaciju rezultata istraživanja.

**Mjere centralne tendencije** odgovaraju na pitanje koja je tipična vrijednost u podacima. **Aritmetička sredina** ($\bar{X}$) izračunava se zbrajanjem svih vrijednosti i dijeljenjem s brojem opservacija, koristi sve podatke i ima izvrsna matematička svojstva, ali je osjetljiva na ekstremne vrijednosti, te se preferira za intervalne i omjerne podatke sa simetričnom distribucijom. **Medijan** je srednja vrijednost u sortiranom nizu podataka, robustan je na outliere jer koristi samo informaciju o poziciji, i preferira se za ordinalne podatke ili kada distribucija sadrži ekstremne vrijednosti. **Mod** je vrijednost koja se pojavljuje najčešće, jedina je smislena mjera za nominalne podatke i može ukazati na postojanje više subgrupa u podacima kroz bimodalnu ili multimodalnu distribuciju. U R-u se ove mjere izračunavaju funkcijama `mean()`, `median()`, te kombinacijom `table()` i `which.max()`.

**Mjere disperzije** kvantificiraju koliko su podaci raspršeni oko središnje vrijednosti. **Raspon** je razlika između maksimuma i minimuma – jednostavan ali potpuno osjetljiv na outliere. **Međukvartilni raspon** (IQR) je razlika između trećeg i prvog kvartila, robustan na outliere jer mjeri varijabilnost "srednje polovice" podataka. **Varijanca** ($s^2$) je prosječno kvadrirano odstupanje od prosjeka, matematički fundamentalna ali teško interpretabilna zbog kvadratnih jedinica. **Standardna devijacija** ($s$) je kvadratni korijen varijance, izražena u izvornim jedinicama i interpretira se pomoću empirijskog pravila prema kojem 68% podataka pada unutar jedne, 95% unutar dviju, a 99.7% unutar triju standardnih devijacija od prosjeka. U R-u se koriste funkcije `range()`, `IQR()`, `var()` i `sd()`.

**Standardizirani rezultati** (z-vrijednosti) transformiraju sirove rezultate u broj standardnih devijacija od prosjeka prema formuli $z = (X - \bar{X})/s$, čime centriraju distribuciju oko nule i skaliraju je na standardnu devijaciju od 1, omogućujući usporedbe između različitih skala. **Pearsonov koeficijent korelacije** ($r$) mjeri jačinu i smjer linearnog odnosa između dviju varijabli, varirajući od -1 do +1, a izračunava se kao standardizirana kovarijanca. Ključna napomena jest da korelacija ne implicira uzročnost, te su za kauzalne zaključke potrebni eksperimentalni dizajni ili napredne kauzalne metode. U R-u se koriste funkcije `scale()` za standardizaciju i `cor()` za korelaciju.

**Vizualizacija podataka** omogućuje intuitivnije razumijevanje distribucija i obrazaca. **Histogram** prikazuje oblik distribucije numeričke varijable, **box plot** sažima distribuciju kroz kvartile i identificira outliere, **dijagram raspršenja** prikazuje odnos između dviju

numeričkih varijabli, a **stupčasti grafikon** prikazuje frekvencije kategorijskih varijabli. Sve vizualizacije u R-u kreiraju se paketom ggplot2 pomoću funkcija `geom_histogram()`, `geom_boxplot()`, `geom_point()` i `geom_col()`.

Pri izvještavanju rezultata, aritmetička sredina uvijek se navodi zajedno sa standardnom devijacijom ($M$, $SD$), dok se medijan navodi s međukvartilnim rasponom ($Mdn$, $IQR$). Brojke se zaokružuju na dvije decimale i uvijek se kontekstualiziraju objašnjavajući što znače u kontekstu istraživačkog pitanja. Vizualizacije služe kao dopuna numeričkim statistikama, ne kao njihova zamjena, i mogu otkriti obrasce koje same brojke ne pokazuju.

Valjano provođenje deskriptivne analize čini temelj svake naprednije statističke obrade. Prije nego što se pristupi testiranju hipoteza (poglavlje 9) ili regresijskoj analizi (poglavlje 10), nužno je temeljito upoznati podatke kroz deskriptivnu statistiku. Ova faza analize omogućuje otkrivanje potencijalnih problema u podacima, poput outliera ili neočekivanih distribucija, informira odluke o prikladnim statističkim metodama i pruža kontekst za interpretaciju naprednih analiza. Deskriptivna statistika nije samo "uvodni korak" – ona je integralni dio svakog kvalitetnog istraživanja koji omogućuje dublje razumijevanje fenomena koji se istražuje.